

BERNARDO RIBEIRO

Licenciatura em Engenharia Química e Biológica

AVALIAÇÃO DA FIABILIDADE DA MONITORIZAÇÃO DO DESEMPENHO ENERGÉTICO NA INDÚSTRIA DE PROCESSO CONTÍNUO

MESTRADO EM ENGENHARIA QUÍMICA E BIOLÓGICA

Universidade NOVA de Lisboa

Draft: 13 de setembro de 2026

AVALIAÇÃO DA FIABILIDADE DA MONITORIZAÇÃO DO DESEMPENHO ENERGÉTICO NA INDÚSTRIA DE PROCESSO CONTÍNUO

BERNARDO RIBEIRO

Licenciatura em Engenharia Química e Biológica

Orientador: Mário Eusébio

Professor, NOVA School of Science and Technology

Coorientador: Nuno Miranda

Galp Energia, Refinaria de Sines

MESTRADO EM ENGENHARIA QUÍMICA E BIOLÓGICA

Universidade NOVA de Lisboa

Draft: 13 de setembro de 2026

RESUMO

Palavras-chave: desempenho energetico; baselines energeticas; ISO 50001; ISO 50006; processos continuos; refinacao; monitorizacao; validacao estatistica

ABSTRACT

Keywords: energy performance; energy baselines; ISO 50001; ISO 50006; continuous process industries; oil refining; monitoring; statistical validation

DECLARAÇÃO DE DELEGAÇÃO A INTELIGÊNCIA ARTIFICIAL GENERATIVA

O autor, Bernardo Ribeiro, reconhece a utilização das seguintes ferramentas de inteligência artificial generativa no desenvolvimento desta tese. Estas tecnologias foram utilizadas sob rigorosa supervisão, e todos os resultados gerados por IA foram criticamente revistos e verificados quanto à sua exatidão. O autor assume total responsabilidade pela validade e originalidade do conteúdo, confirmando que a utilização destas ferramentas está em conformidade com todas as políticas institucionais e normas de integridade acadêmica.¹

Ferramentas de IA Generativa utilizadas: Não foram declaradas ferramentas de IA Generativa.

Atividades apoiadas por Ferramentas de Inteligência Artificial Generativa:²

Concetualização

- | | | |
|--|---|---|
| ☐ Geração de ideias | ☐ Formulação de questões de investigação e hipóteses | ☐ Verificações preliminares (exploratórias) de hipóteses |
| ☐ Definição do objetivo de investigação | ☐ Avaliação de viabilidade e análise de risco | ☐ Debate simulado e teste de argumentos |

Revisão de Literatura

- | | | |
|--|---|---|
| ☐ Pesquisa e Descoberta | ☐ Mapeamento de Conceitos e Sistematização | ☐ Identificação de Lacunas e Avaliação de Novidade |
| ☐ Resumo de fontes externas | ☐ Análise de panorama de mercado/patentes | ☐ Compreensão de literatura multilingue |

Metodologia

- | | | |
|--|---|---|
| ☐ Desenho de investigação | ☐ Desenvolvimento de protocolos experimentais ou de investigação | ☐ Seleção de métodos de investigação |
|--|---|---|

¹Esta declaração foi gerada usando pdfL^AT_EX [51] e o pacote L^AT_EX aidisclose [35].

²Esta lista estende a taxonomia GAIDeT [49].

Desenvolvimento de Software e Automação

- | | | |
|---|---|--|
| ☐ Geração de código | ☐ Depuração e Reparação | ☐ Design de algoritmos |
| ☐ Refatoração e Otimização | ☐ Automação de processos | ☐ Documentação de código e geração de comentários |

Gestão de Dados

- | | | |
|---|--|---|
| ☐ Recolha de dados | ☐ Geração de figuras a partir de dados | ☐ Geração de dados sintéticos |
| ☐ Validação | ☐ Verificações de reprodutibilidade e re-execução | ☐ Apoio à desidentificação e anonimização |
| ☐ Limpeza de dados | | ☐ Transcrição de áudio para texto e diarização |
| ☐ Curadoria e organização de dados | ☐ Assistência na rotulagem e anotação de dados | |
| ☐ Análise de dados | | |

Visuais e Multimédia

- | | | |
|---|--|---|
| ☐ Geração de imagem/diagrama (sintética) | ☐ Melhoria e Edição de Imagem | ☐ Design e layout de figuras |
|---|--|---|

Escrita e Edição

- | | | |
|---|--|--|
| ☐ Redação de Texto | ☐ Adaptação e ajuste de tom emocional | ☐ Comunicados de imprensa e materiais de divulgação |
| ☐ Polimento e Edição | ☐ Tradução | ☐ Geração de Título |
| ☐ Resumo de texto | ☐ Formatação e Codificação de Referências | |
| ☐ Formulação de conclusões | | |

Revisão Ética

- | | | |
|---|---|--|
| ☐ Análise de viés e avaliação de discriminação | ☐ Monitorização de conformidade com padrões éticos | ☐ Monitorização de confidencialidade de dados |
| ☐ Análise de risco ético | | |

Garantia de Qualidade

- | | | |
|--|--|---|
| ☐ Revisão por Pares Simulada | ☐ Identificação de limitações | ☐ Apoio à publicação |
| ☐ Identificação de tendências | ☐ Sugestões Estratégicas | |

ÍNDICE

Resumo	ii
Abstract	iii
Declaração de Delegação a Inteligência Artificial Generativa	iv
Índice	vi
Índice de Figuras	ix
Índice de Tabelas	x
1 Introdução	1
1.1 Contexto e motivação	1
1.2 Formulação do problema	2
1.3 Objetivos e questões de investigação	3
1.4 Contribuições	4
1.5 Âmbito e enquadramento do trabalho	5
1.6 Estrutura do documento	6
2 Enquadramento	8
2.1 Gestão de energia e o quadro normativo	8
2.2 <i>Baselines</i> energéticas: conceitos e construção	9
2.2.1 O par EnPI–EnB	9
2.2.2 A cadeia de medição implícita	10
2.2.3 Onde as normas param e a implementação começa	12
2.3 A assimetria normativa	13
2.3.1 Formulação	13
2.3.2 Matriz de rastreabilidade: cláusula, silêncio, pressuposto, teste	14
2.3.3 O silêncio como escolha: comparação com o IPMVP e a ASHRAE Guideline 14	15
2.3.4 Síntese	17
2.4 Especificidade dos processos contínuos	17
2.5 O caso de estudo: a refinaria de Sines e a unidade de destilação atmosférica	17

3	Revisão sistemática do âmbito	18
3.1	Protocolo e pré-registo	18
3.2	Estratégia de pesquisa e seleção	18
3.3	Análise bibliométrica (Corpus A)	18
3.4	Síntese narrativa (Corpus B)	18
3.5	Síntese: o <i>gap</i>	18
4	Materiais e métodos	19
4.1	Fontes de dados e ingestão	19
4.2	Modelo dimensional e reconciliação	21
4.3	Cálculo de métricas energéticas	22
4.4	Protocolo de avaliação estatística das <i>baselines</i>	24
4.5	Reprodutibilidade e proveniência	26
5	Resultados I — A plataforma	28
5.1	Arquitetura entregue	28
5.2	Validação da camada de dados	29
5.3	O <i>dashboard</i>	31
5.4	Cobertura e limitações da plataforma	33
6	Resultados II — Diagnóstico das baselines	35
6.1	O modelo sob análise: replicação exata	35
6.2	Perfil dos dados e domínio de validade	36
6.3	Poder preditivo contra referências triviais	37
6.4	Estabilidade dos parâmetros	38
6.5	Calibração das bandas de alarme	39
6.6	Detetabilidade	40
6.7	Suficiência da variável explicativa	41
6.8	Diagnósticos complementares	42
6.9	Síntese: os modos de falha	44
7	Discussão e proposta metodológica	47
7.1	Leitura integrada do diagnóstico	47
7.2	Implicações para a conformidade normativa	49
7.3	Linhas orientadoras para a construção e aceitação de <i>baselines</i>	50
7.4	Demonstração na unidade	52
7.4.1	Estimadores robustos	52
7.4.2	Bandas honestas	53
7.4.3	O critério de aceitação e o que decidiu	54
7.4.4	Fichas por <i>baseline</i>	55
7.5	Referência congelada e verdade conhecida	55
7.5.1	O que muda quando não se reajusta	56

7.5.2	Monitor e <i>baseline</i> com verdade conhecida	57
7.6	Implicações para a plataforma	59
7.7	Limitações	60
8	Conclusões e trabalho futuro	62
8.1	Conclusões	62
8.2	Roteiro de modelos sucessores	62
8.3	Trabalho futuro	62
	Bibliografia	63
	Apêndices	
A	Protocolo da revisão sistemática e <i>amendments</i> OSF	68
B	Protocolo de validação da extração e fluxo PRISMA	69
C	Dicionário de dados e mapeamento mestre	70
D	Tabelas completas do diagnóstico	71
E	Manual do <i>dashboard</i>	72
F	Registro da revisão adversarial da metodologia	73
G	Definições matemáticas dos instrumentos de avaliação	74

ÍNDICE DE FIGURAS

2.1	A família ISO 50001 e o par EnPI–EnB no ciclo PDCA	9
2.2	A cadeia de medição normativa e os seus pressupostos tácitos	10
2.3	O conceito EnPI/EnB/meta e a extensão de implementação	13

ÍNDICE DE TABELAS

2.1	Tipologia de EnPI da ISO 50006 e localização do método em produção . . .	11
2.2	Matriz de rastreabilidade cláusula–silêncio–pressuposto–teste	14
2.3	Comparação de quadros normativos quanto a requisitos de validação	16
6.1	Igualdade dos declives anuais	38
6.2	Valor incremental das covariáveis	42
6.3	Síntese do diagnóstico por vetor	45
7.1	Os três estimandos deste capítulo	49
7.2	Estimadores robustos contra mínimos quadrados	53
7.3	Bandas alternativas nos vinte pares	53
7.4	Critério de aceitação: candidatos de mínimos quadrados	54
7.5	Contrastes co-primários com verdade conhecida	58

ÍNDICE DE LISTAGENS

INTRODUÇÃO

1.1 Contexto e motivação

Uma refinaria mede tudo e sabe pouco sobre a sua energia. A de Sines não é exceção: cada caudal, cada temperatura e cada consumo de combustível ficam registados no historiador de processo; os balanços mensais de produção e de utilidades fecham-se e arquivam-se; a eletricidade é medida, faturada e repartida pelas unidades. E, contudo, quando se pergunta se uma unidade consome hoje mais do que devia à carga que tem, a resposta não sai de nenhum destes sistemas: sai da pessoa que os cruza à mão. Os dados existem em três lugares que não se falam, o historiador, as bases de dados dos balanços e os ficheiros de cálculo das equipas, e a monitorização do desempenho energético vive na fronteira entre eles, reconciliada caso a caso e nunca de forma sistemática.

O pedido que deu origem a este trabalho foi, na sua formulação inicial, um *dashboard*: uma plataforma que juntasse as fontes, calculasse os indicadores que a equipa de monitorização já produzia e os mostrasse por unidade, por vetor energético e por dia. É um pedido legítimo, e foi cumprido. Mas um *dashboard* é uma resposta, e a pergunta que ele esconde é outra, e é a desta dissertação: *o que é preciso para que uma plataforma de monitorização energética seja fiável?* Fiável no sentido estrito: um alarme que emite significa o que diz, e a ausência de alarme significa que não havia nada a assinalar.

A fiabilidade tem duas camadas, e a segunda é a que costuma faltar. A primeira é a dos dados: a plataforma tem de dizer a verdade sobre o que a unidade consumiu e processou, o que exige três fontes reconciliadas num modelo único, com cada divergência explicada. A segunda é a da analítica: a plataforma tem de saber o que fazer com essa verdade, e o que faz com ela é compará-la com uma referência — uma *baseline* energética — que diz quanto a unidade devia ter consumido àquela carga. Se a *baseline* estiver errada, os dados podem estar certos e o alarme continuar a não significar nada.

As duas camadas não são uma escolha de desenho; são as duas metades de um requisito. A ISO 50001 obriga a organização a monitorizar, medir e analisar o seu desempenho energético e a responder a desvios significativos [40, §9.1]; a ISO 50006 operacionaliza a comparação através do par indicador–referência, os indicadores de desempenho energético (EnPI) e os consumos energéticos de referência (EnB, as *baselines*) [26]. A infraestrutura de

medição é a primeira metade; a *baseline* validada é a segunda. Um sistema de gestão de energia pode ter a primeira e não ter a segunda, e é o que esta dissertação encontrou em Sines: um método de *baseline* aplicado com disciplina há seis anos, reproduzível ao dígito, cuja adequação ao fim que a norma lhe atribui não tinha sido posta à prova.

Isto importa por uma razão que só se vê de dentro. Um sistema de alarmes construído sobre uma *baseline* que se reajusta todos os anos aprende a tratar como normalidade o que devia assinalar. A unidade degrada-se devagar — incrustação nos permutadores, desativação de catalisador, uma alteração operacional que ninguém registou — e, em cada janeiro, a *baseline* absorve a deriva do ano anterior e volta a zero. Sobram para os alarmes os desvios rápidos; os lentos, que são os que a gestão de energia existe para apanhar, ficam invisíveis por construção. Esta dissertação parte do pedido de um *dashboard* e chega a essa pergunta.

1.2 Formulação do problema

O problema tem duas partes, e a segunda explica por que razão a primeira não se resolve com mais dados.

A primeira é uma assimetria normativa. A ISO 50001 é uma norma de requisitos: diz o que deve existir (indicadores, *baselines*, normalização quando há variáveis relevantes, resposta a desvios) e é certificável sobre isso. A ISO 50006 e a ISO 50015 são normas de orientação: descrevem como construir uma *baseline* e como medir e verificar, sem carácter vinculativo [26, 28]. Nenhuma das três fixa um critério pelo qual uma *baseline* é aceite ou rejeitada. A organização é obrigada a comparar o desempenho com a referência e a reagir ao que vê; não é obrigada a demonstrar que a referência merece a comparação. O Capítulo 2 percorre esta assimetria cláusula a cláusula e mostra que o silêncio é uma escolha de desenho normativo, não uma impossibilidade técnica: protocolos de medição e verificação nascidos no setor dos edifícios fixam critérios quantitativos, e a família ISO cita-os sem os adotar.

A segunda parte é um pressuposto que as normas fazem sem o enunciar. Normalizar o consumo pela carga, comparar períodos «em condições equivalentes» e alarmar sobre um desvio só faz sentido se a relação entre consumo e variáveis relevantes for estável no tempo — se o que a unidade consumia a uma dada carga no período de referência for o que consome a essa carga hoje. É um pressuposto de estacionariedade da relação, não da série, e é razoável em muitos contextos: um edifício, uma linha de montagem. Em processo contínuo é falso por física. Um forno incrusta e perde eficiência de transferência de calor; um catalisador desativa-se e exige temperaturas mais altas para o mesmo resultado; a carga muda de composição com cada crude; a manutenção repõe parte do que se perdeu e o ciclo recomeça. A relação consumo–carga deriva, e deriva devagar. Um modelo estático, ajustado sobre um período fixo, não tem forma de distinguir essa deriva estrutural de uma perda de eficiência que a operação pudesse corrigir: vê apenas resíduos. E se o modelo for reajustado todos os anos, deixa de ver sequer os resíduos.

O que está em jogo é operacional e normativo ao mesmo tempo. Operacional, porque uma *baseline* que não distingue deriva de ineficiência produz alarmes que a operação aprende a ignorar e silêncios que a gestão aprende a ler como normalidade. Normativo, porque uma organização pode estar em conformidade formal com a ISO 50001 (tem EnPI, tem EnB, normaliza, reporta) e não ter forma de saber se as suas *baselines* cumprem alguma das três funções que lhes são pedidas: normalizar o consumo pela carga, sustentar comparações entre períodos e alimentar alarmes. A certificação não pergunta; a norma não exige que se pergunte.

É este o problema: *não existe uma metodologia sistemática para avaliar e construir baselines energéticas em processo contínuo dentro do enquadramento normativo em vigor, e, sem ela, uma organização não tem meio de saber se a sua plataforma de monitorização é fiável na segunda camada, por mais fiável que seja na primeira.* O Capítulo 3 pergunta à literatura se alguém o resolveu; os capítulos empíricos mostram o que ele custa numa refinaria real e o que é preciso para o tratar.

1.3 Objetivos e questões de investigação

A pergunta central já foi enunciada: o que é preciso para que uma plataforma de monitorização energética seja fiável, nas duas camadas. Responde-se-lhe com três objetivos encadeados, em que cada um é a condição do seguinte.

O primeiro é *construir*: reunir as três fontes de dados da refinaria num modelo dimensional único; validar que esse modelo reproduz os números oficiais, célula a célula, com cada divergência explicada; calcular sobre ele as métricas energéticas que a equipa de monitorização usa; e entregar o resultado em produção. Este objetivo responde ao pedido industrial e produz o instrumento.

O segundo é *diagnosticar*: replicar exatamente, dentro desse instrumento, o método de *baseline* que a refinaria usa há seis anos, e avaliá-lo com um protocolo estatístico especificado e selado antes de qualquer resultado: poder preditivo contra referências triviais, estabilidade dos parâmetros, calibração das bandas de alarme, detetabilidade e suficiência da variável explicativa, com correção de multiplicidade e análise de sensibilidade às convenções herdadas do método. A replicação exata é o que garante que se critica o método real e não uma reconstrução dele.

O terceiro é *prescrever*: converter o diagnóstico numa proposta, linhas orientadoras para construir, aceitar e manter *baselines* em processo contínuo, com um critério de aceitação declarado antes dos resultados; demonstrá-la na própria unidade; e devolvê-la à plataforma como especificação do que o *dashboard* tem de mostrar para que uma *baseline* seja usada com conhecimento do seu estado.

Os três objetivos são acompanhados por uma revisão sistemática do âmbito da literatura, pré-registada e reportada segundo a PRISMA-ScR [52], cuja pergunta primária é em que medida os modelos de medição do desempenho energético propostos na literatura para cumprir o enquadramento ISO 50001/50006 são adequados à indústria de processo

contínuo, e que adaptações metodológicas são necessárias para a sua aplicação. Quatro subquestões a decompõem, e são também as subquestões desta dissertação: a literatura responde-lhes a partir do que está publicado; os capítulos empíricos, a partir de um caso real.

- SQ1** Que modelos de medição do desempenho energético existem no âmbito do enquadramento ISO 50001/50006, para que contextos foram desenvolvidos e validados, e como se distribuem por tipo de organização? — respondida pela análise bibliométrica do Corpus A (Capítulo 3).
- SQ2** Que mecanismos de variabilidade operacional, específicos da indústria de processo contínuo, podem tornar esses modelos inadequados para uma monitorização contínua alinhada com as normas de referência? — respondida pela síntese narrativa do Corpus B e, empiricamente, pelo diagnóstico do Capítulo 6: o caso confirma ou contradiz o que a literatura antecipa.
- SQ3** Como podem os modelos de EnPI e EnB ser adaptados à variabilidade operacional dos processos contínuos, dentro dos requisitos das normas de referência? — respondida pelas adaptações identificadas no Corpus B e pelas linhas orientadoras do Capítulo 7.
- SQ4** Em que medida as recomendações metodológicas identificadas são aplicáveis e operacionalizáveis numa refinaria real? — respondida pela demonstração na unidade e pelas implicações para a plataforma (Capítulo 7).

O desenho de investigação assenta em três rotas de evidência, cada uma com a sua regra fixada antes do resultado. A revisão diz o que existe: o protocolo foi depositado antes da pesquisa e cada alteração posterior é uma emenda datada (Anexo A). O caso real diz o que acontece: o método de produção é replicado com exatidão, sobre os dados da própria refinaria, antes de ser avaliado. O protocolo de avaliação diz como se sabe: os estimandos, os testes, os limiares e a correção de multiplicidade foram fixados e submetidos a revisão adversarial antes de se olhar para um resultado (Anexo F), na lógica do pré-registo [39], e uma grelha de sensibilidade reavalia as conclusões sob variações das convenções que o método herdou.

1.4 Contribuições

As contribuições dividem-se pelas duas metades do requisito. As primeiras pertencem à refinaria; as segundas a qualquer organização que opere *baselines* energéticas sobre processo contínuo.

Para a refinaria, entregam-se três coisas. Uma plataforma de monitorização energética em produção, sobre um modelo dimensional único que reconcilia as três fontes e cobre dezasseis unidades processuais em três fábricas, validada contra os números oficiais célula a célula (Capítulo 5). Um *dashboard* desenhado como percurso de diagnóstico, da refinaria

para a unidade, da unidade para o vetor, do vetor para a *baseline* que o julga (Secção 5.3). E a especificação de um bloco de saúde das *baselines*: duas pistas em vez de uma, domínio de validade visível, calibração monitorizada em vez de assumida, uma ficha por *baseline* e políticas de estado registadas, formulada como requisitos, cada um ancorado num resultado (Secção 7.6).

As contribuições metodológicas são quatro. Um protocolo de avaliação de *baselines* energéticas, especificado antes dos resultados, com correção de multiplicidade e grelha de sensibilidade, reutilizável em qualquer unidade que opere *baselines* lineares anuais (Secção 4.4). O diagnóstico do método em produção: cinco modos de falha qualitativamente distintos, um por vetor energético, e o mecanismo que os liga — a recalibração anual absorve a deriva que devia expor, e o sistema fica cego por construção aos fenómenos lentos e ruidoso nos rápidos (Capítulo 6). Linhas orientadoras para *baselines* em processo contínuo, com um critério de aceitação selado e demonstradas na unidade, incluindo o que muda quando se congela uma referência em vez de a reajustar e o que um monitor sequencial consegue detetar quando a verdade é conhecida por simulação (Capítulo 7). E uma revisão sistemática do âmbito pré-registada, com corpus fechado e instrumento de extração auditável, que situa o caso na literatura (Capítulo 3; Anexos A e B).

As quatro últimas não existiriam sem as três primeiras, e as três primeiras ficariam por acabar sem as quatro últimas: o instrumento foi construído para tornar o diagnóstico possível, e o diagnóstico devolve-lhe a especificação de que ele precisava.

1.5 Âmbito e enquadramento do trabalho

O trabalho decorreu num estágio curricular na Refinaria de Sines da Galp, entre fevereiro e julho de 2026, integrado na equipa responsável pela monitorização energética, com orientação académica na NOVA FCT e orientação industrial na refinaria. A plataforma foi construída, validada e entregue nesse período; o diagnóstico e a proposta foram concluídos depois, sobre uma extração completa e verificada dos dados e do modelo, feita antes da saída.

As fronteiras são quatro, todas escolhidas.

Uma unidade. O caso é a unidade de destilação atmosférica (CDU), com os seus cinco vetores energéticos (fuel gás, três níveis de vapor e eletricidade), quatro dos quais com resolução diária; a eletricidade é uma alocação mensal e fica fora de qualquer inferência diária. A CDU é a porta de entrada do esquema de refinação, processa todo o crude, e a incrustação da sua bateria de pré-aquecimento é o caso canónico de deriva lenta em processo contínuo: se um método de *baseline* estático falha, é aqui que falha de forma legível.

A classe linear estática como objeto. O método de produção é uma regressão linear anual do consumo sobre a carga, e é essa classe que se diagnostica e que as linhas orientadoras levam ao máximo defensável: domínio explícito, exclusões por causa, estimação robusta, bandas que respeitam a dependência, critério de aceitação. Modelos com estado de degradação,

que seriam a resposta completa à não-estacionariedade, ficam fora: o Capítulo 8 traça o roteiro para eles e explica por que razão os critérios de aceitação aqui construídos são a condição para lá chegar.

Sem inferência causal. Nenhum desvio é classificado como ineficiência e nenhum alarme como falso, porque isso exige o calendário operacional, os rótulos de eventos e as margens materiais elicitadas com a operação, que não estavam disponíveis. A dissertação mede o que o método vê e o que não vê; não diz o que a unidade devia ter feito.

Monitorização contínua, não medição e verificação de projetos. Os protocolos de M&V tratam de provar as poupanças de uma intervenção; aqui o objeto é a *baseline* que julga cada dia de operação, um problema distinto que partilha instrumentos com o primeiro.

Estas fronteiras têm um custo, e declara-se já. Uma unidade e um único *snapshot* de dados já explorados não permitem afirmações fora de amostra, e a demonstração das linhas orientadoras é retrospectiva. A eletricidade fica sem diagnóstico diário. O que a recalibração anual mascarou em cada ano não é mensurável sem o calendário operacional. A Secção 7.7 desenvolve cada uma destas limitações; enunciam-se aqui para que se saiba desde o início o que este trabalho não pode dizer.

1.6 Estrutura do documento

A dissertação lê-se em três andamentos, instrumento, diagnóstico e prescrição, precedidos por dois capítulos que estabelecem o que as normas exigem e o que a literatura oferece.

O Capítulo 2 reconstrói a cadeia de medição implícita na família ISO 50001 e mostra, cláusula a cláusula, onde a norma exige, onde deixa à organização e que pressuposto tácito cada elo importa para funcionar; introduz a especificidade dos processos contínuos e apresenta o caso de estudo. O Capítulo 3 pergunta à literatura se o problema está resolvido: protocolo e pré-registo, estratégia de pesquisa e seleção, análise bibliométrica do Corpus A, síntese narrativa do Corpus B e a formulação do *gap* que o resto do documento trata.

O Capítulo 4 descreve como se construiu e como se avaliou: fontes e ingestão, modelo dimensional e reconciliação, cálculo de métricas, o protocolo de avaliação estatística das *baselines* e a cadeia de proveniência que torna cada número reproduzível. O Capítulo 5 é o instrumento: a arquitetura entregue, a prova de que a camada de dados diz a verdade, o *dashboard* e o que ficou de fora. O Capítulo 6 executa-se sobre o modelo de dados do capítulo anterior (é, literalmente, uma consulta a ele) e audita a camada analítica: replicação exata, perfil dos dados e domínio de validade, as quatro dimensões do protocolo e os diagnósticos complementares, fechados numa síntese dos modos de falha. O Capítulo 7 lê o diagnóstico em conjunto, tira as implicações para a conformidade normativa, propõe as linhas orientadoras, demonstra-as na unidade, devolve-as à plataforma como especificação e declara os limites do que afirma. O Capítulo 8 conclui e traça o roteiro dos modelos sucessores.

Os anexos guardam o que o corpo cita e não reproduz. Da revisão, o protocolo e as emendas (Anexo A) e a validação da extração com o fluxo PRISMA (Anexo B). Da

plataforma, o dicionário de dados e o mapeamento mestre (Anexo C) e o manual do *dashboard* (Anexo E). Do diagnóstico, as tabelas completas (Anexo D), o registo da revisão adversarial da metodologia (Anexo F) e as definições matemáticas dos instrumentos de avaliação (Anexo G).

No fim do percurso, a pergunta com que este capítulo abriu, se uma unidade consome hoje mais do que devia à carga que tem, continua a ser feita à mesma plataforma. A diferença é que a resposta passa a trazer consigo a ficha da *baseline* que a produziu, o domínio em que essa *baseline* é válida, a cobertura efetiva da sua banda e a data em que a referência foi congelada. É essa a distância entre um *dashboard* e uma plataforma fiável.

ENQUADRAMENTO

2.1 Gestão de energia e o quadro normativo

A gestão de energia industrial encontra-se hoje codificada num corpo normativo estruturado em torno da ISO 50001, que especifica os requisitos de um sistema de gestão de energia (SGE), e de um conjunto de normas de suporte, desenvolvidas pelo comité técnico ISO/TC 301, que operacionalizam componentes específicos desse sistema. Para o presente trabalho relevam três documentos: a ISO 50001:2018, adotada em Portugal como NP EN ISO 50001:2019 [40], que estabelece os requisitos do sistema; a ISO 50006 [26], que fornece princípios e orientações para a medição do desempenho energético através de indicadores de desempenho energético (EnPI, na sigla anglófona que a literatura consagrou; IDE na versão portuguesa da norma) e consumos energéticos de referência (EnB, ou CER); e a ISO 50015 [28], que estabelece princípios gerais para a medição e verificação (M&V) do desempenho energético de organizações. A distinção de estatuto entre estes documentos é essencial para a análise que se segue: a ISO 50001 é uma norma de requisitos, certificável, redigida na forma verbal «deve»; a ISO 50006 e a ISO 50015 são normas de orientação, redigidas na forma «deverá/poderá», sem carácter vinculativo — a própria ISO 50015 declara que os seus princípios não são exigidos pela ISO 50001 [28, Introdução].

A ISO 50001 estrutura o SGE sobre o ciclo de melhoria contínua *Plan-Do-Check-Act* (PDCA). Na fase de planeamento, a organização realiza uma avaliação energética (§6.3), identifica os usos significativos de energia (USE), determina EnPI «adequados para medir e monitorizar o seu desempenho energético» e que «permitam demonstrar a melhoria do desempenho energético» (§6.4), e estabelece EnB a partir da avaliação energética, «tendo em conta um período de tempo adequado» (§6.5). Na fase de verificação, a organização monitoriza, mede, analisa e avalia o desempenho (§9.1): a melhoria do desempenho energético «deve ser avaliada comparando os valores de IDE [...] com os correspondentes CER», e a organização «deve investigar e responder a desvios significativos no desempenho energético» (§9.1.1). O par EnPI–EnB é, portanto, o mecanismo central através do qual a norma torna o desempenho energético mensurável e a melhoria demonstrável — e é sobre este par que incide toda a análise desta dissertação.

A ISO 50006 desenvolve o par EnPI–EnB. Define o processo de medição do desempenho




Figura 2.1: A família ISO 50001 e a localização do par EnPI–EnB no ciclo PDCA. Adaptado de [40, 26].

em cinco passos — obtenção de informação a partir da avaliação energética, identificação dos EnPI, estabelecimento dos EnB, utilização de ambos, e manutenção e ajustamento [26, Figura 2] — e introduz os conceitos operativos de que o Capítulo 6 fará uso intensivo: fronteira do EnPI (§4.2.2), variável relevante (§3.14: fator quantificável com impacto significativo no desempenho energético e que muda rotineiramente), fator estático (§3.17: fator com impacto significativo que não muda rotineiramente) e normalização (§3.13: modificação dos dados energéticos para permitir comparação de desempenho «em condições equivalentes»). A norma tipifica ainda os EnPI em quatro classes — valor medido, rácio de valores medidos, modelo estatístico e modelo de engenharia (§4.3.3, Tabela 2) — tipologia a que regressamos na Secção 2.2 por ser o ponto onde o método de *baseline* usado na refinaria se localiza dentro do vocabulário da própria norma.

A ISO 50015, por fim, enquadra a M&V como processo: plano de M&V documentado, fronteiras, seleção de métricas, plano de recolha de dados, estabelecimento e ajustamento de EnB, análise, reporte e incerteza (§5–§8). Os seus princípios — exatidão apropriada e gestão da incerteza, transparência e reprodutibilidade, competência, imparcialidade, métodos apropriados (§4) — são, nas palavras da norma, princípios e não requisitos (§4.1). No plano internacional coexistem com a família ISO dois protocolos de M&V com génese no setor dos edifícios e dos contratos de desempenho energético: o IPMVP [25] e a ASHRAE Guideline 14 [3], ambos citados pela bibliografia da própria ISO 50015. A comparação entre estes protocolos e as normas ISO, desenvolvida na Secção 2.3, é instrutiva precisamente porque revela que o silêncio da família ISO quanto a critérios quantitativos de validação é uma escolha de desenho normativo, não uma impossibilidade técnica.

2.2 Baselines energéticas: conceitos e construção

2.2.1 O par EnPI–EnB

O conceito central é simples: um EnPI é uma «medida ou unidade do desempenho energético, conforme definido pela organização» (ISO 50001, §3.4.4); o EnB é «referência(s) quantitativa(s) que fornecem uma referência para comparação do desempenho energético» (§3.4.7), construída com dados «obtidos de um período específico de tempo e/ou condições,

conforme definido pela organização» (§3.4.7, Nota 1). A melhoria do desempenho energético demonstra-se comparando o valor do EnPI no período de reporte com o valor de referência do período de *baseline* [26, Figuras 1 e 3]. Quando variáveis relevantes afetam significativamente o desempenho, a comparação direta deixa de ser válida e a organização «deve realizar a normalização do(s) valor(es) do IDE e do correspondente CER» (ISO 50001, §6.5) — tipicamente através de um modelo que descreve a relação entre consumo e variáveis relevantes no período de *baseline* [26, §4.5.1 e Anexo D].

Repare-se, desde já, em duas expressões que a redação normativa usa com naturalidade e que carregam todo o peso estatístico do edifício: a comparação deve fazer-se *em condições equivalentes* (ISO 50006, §3.13), e o período de *baseline* deve *capturar a variabilidade dos padrões operacionais* (§4.4.2). Ambas pressupõem que as condições operacionais são descritíveis pelas variáveis escolhidas e que a variabilidade observada num período — tipicamente doze meses (§4.4.2) — é representativa da variabilidade futura. São pressupostos de estacionariedade: não da série de consumo, mas da *relação* entre consumo e variáveis relevantes. Não são enunciados como pressupostos em parte alguma do texto normativo.

2.2.2 A cadeia de medição implícita

Lidas em conjunto, a 50001 (requisitos), a 50006 (construção de EnPI/EnB) e a 50015 (M&V) desenham uma cadeia de medição: uma sequência de operações que transforma dados de processo em declarações sobre desempenho energético e, no limite, em alarmes e decisões. A cadeia nunca é apresentada como tal em nenhuma das normas — cada documento descreve o seu troço — mas a sua reconstrução explícita (Figura 2.2) é o instrumento analítico deste capítulo, porque permite perguntar, elo a elo, três coisas: o que é exigido, o que é deixado à organização, e que pressuposto tácito o elo precisa de importar para funcionar.




Figura 2.2: A cadeia de medição implícita na família ISO 50001 e, em itálico, o pressuposto tácito que cada elo importa. Reconstrução própria a partir de [40, 26, 28].

Percorramos os elos onde o texto normativo é mais revelador.

Variáveis relevantes (elo 3). A ISO 50006 dedica ao problema orientação prática: recomenda gráficos de tendência e diagramas X–Y entre consumo e variável candidata, e observa que «em muitos casos, uma relação linear simples é adequada para determinar a relevância» (§4.2.4). O critério de significância, porém, «é determinado pela organização» (ISO 50001, §3.4.9, Nota 1) — a norma diz *como olhar*, mas não fixa nenhum limiar de decisão, nenhum procedimento de teste e, sobretudo, nenhum teste de *suficiência*: nada obriga a organização a demonstrar que o conjunto de variáveis escolhido esgota a variação sistemática do consumo. A escolha de uma única variável — a carga processada, no caso em estudo — é tão conforme à norma quanto a escolha de cinco.

Tipo de EnPI (elo 4). A Tabela 2 da ISO 50006 é o documento mais interessante de toda a família para o argumento desta dissertação, porque a própria norma enumera, na coluna de observações, as fragilidades de cada tipo. Para o tipo «valor medido»: não tem em conta os efeitos das variáveis relevantes, «dando resultados enganadores na maioria das aplicações». Para o rácio: não considera a carga de base nem efeitos não lineares, sendo «enganador em instalações com carga de base elevada». Para o modelo estatístico: «pode ser impreciso se não for confirmado por testes estatísticos» e «os modelos devem ser mantidos para assegurar resultados válidos» (§4.3.3, Tabela 2).¹ A norma conhece, portanto, os modos de falha — enuncia-os — mas não converte nenhum deles em requisito verificável: não diz *que testes, com que limiares, com que frequência, nem o que fazer* quando falham. A Tabela 2.1 condensa esta tipologia e localiza o método em produção na refinaria — regressão linear univariada por vetor energético, $E = a \cdot Q + b$ — na classe «modelo estatístico», herdando por escrito os *caveats* que a própria norma lhe associa.

Tabela 2.1: Tipologia de EnPI da ISO 50006 (§4.3.3, Tabela 2, condensada; traduções do autor) e localização do método de *baseline* em produção na unidade em estudo.

Tipo de EnPI	Aplicação típica (norma)	Fragilidades enunciadas pela própria norma
Valor medido	Reduções absolutas; monitorização de custos	Ignora variáveis relevantes; «resultados enganadores na maioria das aplicações»
Rácio de valores medidos	Eficiência com uma só variável e carga de base pequena; <i>benchmarking</i>	Ignora carga de base e efeitos não lineares
Modelo estatístico ← <i>método em produção</i>	Várias variáveis relevantes; carga de base; normalização	Impreciso se não confirmado por testes estatísticos; exige manutenção para assegurar validade
Modelo de engenharia	Variáveis numerosas ou interdependentes; fase de projeto	Exige manutenção para assegurar validade

¹Traduções do autor a partir do original inglês; as passagens críticas são reproduzidas no original em nota nas ocorrências seguintes.

Estabelecimento e teste do EnB (elo 5). A cláusula §4.4.3 da ISO 50006 é o ponto de máxima aproximação de toda a família a um requisito de validação — e, por isso mesmo, o ponto onde o silêncio é mais nítido: «Se apropriado, o EnB deverá ser testado quanto à validade, para assegurar que constitui uma referência apropriada para comparação. Quando se usam modelos, a validade do EnB pode ser determinada usando testes estatísticos como o valor- p , o teste F ou o coeficiente de determinação [...]. Se se determinar que um modelo não é válido, a organização deverá considerar ajustar o EnB ou determinar um novo modelo».² Três observações: (i) «se apropriado» e «deverá» — recomendação condicional, não requisito; (ii) os testes são nomeados, mas nenhum limiar de aceitação é fixado; (iii) todos os testes citados (p , F , R^2) pressupõem, para serem válidos, exatamente aquilo que nunca é mandado verificar — independência, homoscedasticidade e normalidade dos resíduos. A norma sugere instrumentos de validação cuja própria validade depende de pressupostos que a norma não manda testar.

Revisão do EnB (elo 7, retroação). A ISO 50001 fixa três gatilhos de revisão do EnB: quando os EnPI «deixaram de refletir o desempenho energético da organização»; quando «ocorram mudanças significativas nos fatores estáticos»; ou «de acordo com um método predeterminado» (§6.5). A ISO 50006 acrescenta os ajustamentos não-rotineiros e nota que os métodos predeterminados «tipicamente repõem o EnB em intervalos definidos» (§3.1, Nota 3), sancionando explicitamente a prática da recalibração periódica. O que nenhum dos gatilhos fornece é um *mecanismo de detecção*: o primeiro é circular (como sabe a organização que os EnPI deixaram de refletir o desempenho, se o instrumento de medição do desempenho são os próprios EnPI?); o segundo pressupõe que a mudança de fator estático é conhecida e identificada; o terceiro — o calendário — não é sensível a mudança nenhuma. O Capítulo 6 mostrará a consequência empírica: a recalibração anual, perfeitamente conforme à norma, absorve no intercepto a deriva estrutural que devia alarmar.

2.2.3 Onde as normas param e a implementação começa

A análise anterior obriga a uma distinção de três camadas, que atravessa toda a dissertação e sem a qual a crítica seria imprecisa. Primeira camada, **o que as normas exigem** (ISO 50001, «deve»): que existam EnPI e EnB, que a melhoria se demonstre por comparação entre ambos, que se normalize quando as variáveis relevantes afetam significativamente o desempenho, que os desvios significativos sejam investigados, e que o EnB seja revisto nos três gatilhos. Segunda camada, **o que as normas sugerem** (ISO 50006/50015, «deverá», anexos informativos): a tipologia de EnPI, testes de validade nomeados sem limiares, o período de *baseline* de doze meses, a gestão da incerteza «ao nível apropriado» (ISO 50015, §4.2) e os diagnósticos possíveis da incerteza de modelo — «estatísticas t , valores de R^2 ,

²No original: «If appropriate, the EnB should be tested for validity to ensure that it is an appropriate reference for comparison. When models are used, the validity of the EnB can be determined using statistical tests such as the P-Value, F-Test or the coefficient of determination [...].» [26, §4.4.3].

valores- p , níveis de confiança, limites de predição do modelo» (ISO 50015, §7, Nota) — «na medida do praticável» (§7). Terceira camada, **o que a implementação escolhe** — e que nenhuma norma prescreve nem proíbe: no caso em estudo, a forma $E = a \cdot Q + b$ com uma única variável explicativa; a estimação por mínimos quadrados ordinários; as bandas de alarme em $\pm 2\sigma$, com σ estimado a partir dos resíduos de treino; e a recalibração anual por calendário.

Esta atribuição precisa é essencial: o objeto da crítica do Capítulo 6 não é a conformidade — o método em produção é conforme, localiza-se dentro do espaço que as normas permitem. O objeto da crítica é o facto de o espaço permitido conter, sem qualquer barreira normativa, implementações cujos pressupostos estatísticos são sistematicamente violados pelos dados a que se aplicam — e de as normas não fornecerem ao operador nenhum instrumento que o alerte para isso. Dito de outro modo: a conformidade normativa não é evidência de validade estatística, e as normas não contêm o mecanismo que permitiria distinguir uma da outra.




Figura 2.3: O conceito EnPI/EnB/meta e a fronteira entre o que a norma desenha e o que a implementação acrescenta. Adaptado de [26, Figura 1].

2.3 A assimetria normativa

2.3.1 Formulação

Chamamos assimetria normativa ao desequilíbrio, documentado cláusula a cláusula na secção anterior, entre a densidade prescritiva das normas quanto à *existência* dos instrumentos de medição do desempenho energético e o seu silêncio quanto à *validade* desses instrumentos. A família ISO 50001 obriga a que haja EnPI, EnB, normalização, investigação de desvios e revisão da referência; nomeia, inclusive, os instrumentos estatísticos com que a validade poderia ser aferida; mas em nenhum ponto converte a aferição em requisito, fixa limiares de aceitação, exige a verificação dos pressupostos dos modelos ou fornece critérios operacionais para detetar que uma referência deixou de ser válida. O resultado prático é que um sistema de gestão certificado pode operar indefinidamente sobre *baselines* estatisticamente inválidas sem que nenhum requisito normativo seja violado — situação que o Capítulo 6 documenta empiricamente para os cinco vetores energéticos da unidade em estudo.

A assimetria tem uma segunda face, menos evidente: as normas embutem pressupostos estatísticos que nunca enunciam. A comparação «em condições equivalentes» pressupõe a suficiência das variáveis relevantes; a extrapolação do modelo de *baseline* para o período de reporte pressupõe a estabilidade estrutural da relação; o período de referência de doze meses pressupõe que um ciclo anual é representativo; os gatilhos de revisão pressupõem que a mudança é observável por quem opera. Nenhum destes pressupostos é neutro num processo contínuo sujeito a *fouling*, desativação de catalisador e deslocamento gradual do espaço operacional — a especificidade desenvolvida na Secção 2.4.

2.3.2 Matriz de rastreabilidade: cláusula, silêncio, pressuposto, teste

A Tabela 2.2 formaliza a análise: para cada cláusula relevante, o que é exigido ou sugerido, o que fica por especificar, o pressuposto tácito que a cláusula importa, e o *endpoint* do protocolo de diagnóstico (Secção 4.4) que o operacionaliza. É esta última coluna que dá ao Capítulo 6 rastreabilidade completa norma → resultado.

Tabela 2.2: Matriz de rastreabilidade: cláusula normativa, silêncio, pressuposto tácito e *endpoint* de diagnóstico que o testa (E1–E6 e bateria descritiva D; ver Secção 4.4).

#	Cláusula	Exige/sugere	Deixa por especificar	Pressuposto tácito	Teste
1	50001 §6.4; 50006 §4.3	EnPI «adequados para medir e monitorizar»	Critério de adequação; teste de conteúdo preditivo	O EnPI mede desempenho, não ruído	E2
2	50001 §3.4.9 N1; 50006 §4.2.4	Determinar variáveis relevantes (métodos gráficos)	Limiar de significância; teste de <i>suficiência</i> do conjunto	As variáveis descrevem o estado operacional	E6
3	50006 §4.4.2	Período que «capture a variabilidade» (tip. 12 meses)	Verificação de representatividade	Um ciclo anual antecipa o futuro	E3, E4
4	50006 §4.4.3	«Testar a validade» do EnB (p , F , R^2 nomeados)	«Se apropriado»; sem limiares; sem verificação de pressupostos dos testes	Resíduos independentes, homoscedásticos, normais	E1, E2, D
5	50001 §6.5; 50006 §4.5, An. D	Normalizar por variáveis relevantes via modelo	Validação do modelo de normalização; incerteza	A relação transporta-se do treino para o reporte	E3
6	50001 §9.1.1	Investigar «desvios significativos»	Definição de significativo (remetida para a organização)	Existe calibração conhecida do desvio	E4
7	50001 §6.5 a)–c); 50006 §4.6, §3.1 N3	Rever o EnB (3 gatilhos; <i>reset</i> periódico sancionado)	Mecanismo de <i>deteção</i> de invalidade; gatilho a) circular	Mudanças invalidantes são conhecidas ou visíveis	E5
8	50015 §7 + Nota	Identificar e quantificar incerteza (t , R^2 , p , limites de predição nomeados)	Obrigatoriedade; limiares; reporte junto ao resultado	A incerteza declarada é gerível caso a caso	E4
9	50015 §4.1, Introd.	Princípios de M&V (exatidão, reprodutibilidade)	«Princípios, não requisitos»; não exigidos pela 50001	A boa prática é adotada voluntariamente	—
10	50006 §4.2.6.4	Rever qualidade dos dados; examinar <i>outliers</i>	Procedimento e critério de exclusão; efeito sobre σ	<i>Outliers</i> são raros e identificáveis	D

A leitura vertical da coluna dos pressupostos produz a lista compacta que estrutura o resto da dissertação: **suficiência** (as variáveis descrevem o estado), **forma** (a classe de modelo captura a relação), **representatividade** (o período de treino antecipa o futuro), **transportabilidade** (a relação não muda entre treino e aplicação), **calibração** (os desvios têm escala conhecida) e **detetabilidade** (a invalidação é observável). As cinco patologias do Capítulo 6 são, uma a uma, violações empíricas destes pressupostos.

2.3.3 O silêncio como escolha: comparação com o IPMVP e a ASHRAE Guideline 14

Poderia argumentar-se que o silêncio quantitativo das normas ISO é inevitável — que critérios de validação universais não podem ser fixados para organizações de todos os tipos e dimensões; é, de resto, a justificação implícita do «conforme definido pela organização» que percorre os três documentos. A comparação com os protocolos de M&V do domínio dos edifícios desmente a inevitabilidade, e fá-lo em três frentes distintas.

Primeira frente: *limiares de calibração de modelos*. A ASHRAE Guideline 14 exige, como requisito de conformidade da via de simulação calibrada, um erro médio normalizado (NMBE) máximo de $\pm 5\%$ e um coeficiente de variação do erro quadrático médio, CV(RMSE), máximo de 15% face a dados de calibração mensais — $\pm 10\%$ e 30% , respetivamente, para dados horários [3, §4.3.2.4 f), §5.3.3.3.10]. As orientações de M&V do programa federal norte-americano (FEMP) adotam exatamente os mesmos limiares, por remissão declarada para a ASHRAE [36, §4.5.3.2, Tabela 4-2]. O IPMVP, que desde as edições de 2009 remete os detalhes técnicos de calibração para a Guideline 14 [45], recomenda adicionalmente — tal como o *ASHRAE Handbook* — que o R^2 de um modelo calibrado nunca seja inferior a 0,75 [45].

Segunda frente, mais próxima do caso em estudo: *limiares sobre o próprio modelo de regressão de baseline*. A via prescritiva de edifício inteiro da Guideline 14 — precisamente o cenário de uma *baseline* de regressão sobre dados de contagem, análogo estrutural do método em produção na refinaria — impõe que o modelo de *baseline* tenha CV(RMSE) máximo de 20% para energia (escalando para 25% e 30% com períodos de reporte mais longos), que o período de *baseline* cubra pelo menos doze meses contínuos com um mínimo de nove pontos válidos, e que *nenhum ponto seja eliminado* do período de *baseline* [3, §4.3.2.1]; a via de simulação calibrada admite exclusões, mas limita-as a 25% dos dados medidos e exige a documentação das razões [3, §4.3.2.4]. O FEMP, na Opção C (análise de regressão sobre dados de faturação — de novo o análogo do caso Galp), formula-o sem ambiguidade: «a validade estatística dos modelos de regressão finais tem de ser demonstrada» [36, §4.4].³

Terceira frente: *incerteza com critério de aceitação*. A Guideline 14 não se limita a pedir que a incerteza seja reportada com cada relatório de poupanças: fixa um teto — a incerteza tem de ser inferior a 50% das poupanças anuais reportadas, a um nível de confiança de 68% [3, §4.3.2.4 h)].

³No original: «Statistical validity of the final regression models must be demonstrated.» [36, §4.4].

Confirmar formul
na edição corrente
IPMVP (EVO 1000
quando o downlo
for aprovado.

Independentemente do juízo sobre estes limiares em concreto — a literatura discute a sua suficiência estatística, e o Capítulo 4 adotará critérios mais exigentes — a sua simples existência demonstra que protocolos com ambição de aplicação geral *conseguem* fixar critérios quantitativos de aceitação de modelos, regras de tratamento de dados e tetos de incerteza. A família ISO 50001 escolheu não o fazer. A Tabela 2.3 sintetiza a comparação.

Tabela 2.3: Comparação de quadros normativos e protocolos de M&V quanto a requisitos de validação de modelos de *baseline*.

Dimensão	ISO 50001:2018	ISO 50006:2014 / 50015:2014	IPMVP	ASHRAE G14
Estatuto	Requisitos (certificável)	Orientação	Protocolo voluntário	<i>Guideline</i>
Validação do modelo de <i>baseline</i>	—	«deverá, se apropriado» (50006 §4.4.3)	Sim, por adesão ao protocolo	Sim (requisito de conformidade)
Limiares quantitativos	Nenhum	Nenhum (testes/diagnósticos apenas nomeados)	$R^2 \geq 0,75$ (rec.); detalhe remetido para a G14	NMBE $\pm 5/\pm 10\%$, CV(RMSE) 15/30% (calibração, §4.3.2.4); CV(RMSE) $\leq 20-30\%$ no modelo de regressão de base (§4.3.2.1)
Tratamento de exclusões e <i>outliers</i>	—	Rever, sem critério (50006 §4.2.6.4)	Justificação exigida	Proibidas na via prescritiva; $\leq 25\%$, documentadas, na simulação
Verificação dos pressupostos dos testes	—	—	Parcial	Parcial
Incerteza reportada com o resultado	—	«na medida do praticável» (50015 §7)	Sim (Apêndice B)	Sim, com teto: $< 50\%$ das poupanças a 68% de confiança
Deteção de invalidação da <i>baseline</i>	3 gatilhos qualitativos (§6.5)	Qualitativa (50006 §4.6; 50015 §5.10.2)	Ajustes não-rotineiros	—

Duas notas de rigor. Primeira: os limiares ASHRAE/IPMVP/FEMP foram desenvolvidos para modelos de energia de edifícios, com sazonalidade meteorológica dominante; a sua transposição direta para processo contínuo não é defendida aqui — o que se importa é o *princípio* de critérios de aceitação explícitos, não os números. Segunda: mesmo estes protocolos são imperfeitos — Ruiz e Bandera [45] documentam inconsistências de definição entre eles e entre as suas sucessivas edições (a confusão sistemática entre MBE e NMBE, fórmulas divergentes, limiares que mudam de versão para versão), e todos são omissos quanto à verificação dos pressupostos distribucionais dos seus próprios índices e quanto à não-estacionariedade estrutural. O *gap* identificado no Capítulo 3 é, portanto, comum a todo o panorama normativo, não exclusivo da família ISO; a família ISO é simplesmente o caso extremo, por não fixar sequer os índices.

Nota sobre as edições analisadas. A presente análise reporta-se à ISO 50006:2014 e à ISO 50015:2014, as edições a que houve acesso e, presumivelmente, as que enquadram o método de *baseline* em produção na instalação em estudo. Existe uma segunda edição da ISO 50006, de 2023, harmonizada com a ISO 50001:2018, que introduz, entre outras alterações, uma cláusula dedicada à incerteza de modelo (§8.2) [27]; não foi possível consultá-la no âmbito deste trabalho. Regista-se como limitação (Secção 7.7): as afirmações desta secção sobre o silêncio normativo estão verificadas contra as edições de 2014, e a possibilidade de a edição de 2023 mitigar parcialmente algum dos silêncios identificados não pôde ser excluída nem confirmada. Assinale-se, porém, que a ISO 50006:2023 mantém o estatuto de norma de orientação, pelo que o argumento central — a ausência de *requisitos* de validação no único documento certificável da família, a ISO 50001 — não depende dessa edição.

Confirmar com a O a edição de referência do SGE.

2.3.4 Síntese

O quadro normativo obriga a medir e a demonstrar melhoria, sugere sem obrigar os instrumentos de validação, e é silencioso sobre os pressupostos estatísticos de que a validade desses instrumentos depende. Para um processo estacionário e bem comportado, o silêncio é inconsequente. A questão a que o resto da dissertação responde empiricamente é o que acontece quando o processo não é estacionário — quando o *fouling*, as transições de consumidores e o deslocamento do espaço operacional fazem parte da física da unidade (Secção 2.4) — e o espaço de implementação permitido pela norma é preenchido pela escolha mais simples que nele cabe: uma regressão univariada estática, com bandas de $\pm 2\sigma$, recalibrada por calendário (Secção 2.5).

2.4 Especificidade dos processos contínuos

2.5 O caso de estudo: a refinaria de Sines e a unidade de destilação atmosférica

REVISÃO SISTEMÁTICA DO ÂMBITO

- 3.1 Protocolo e pré-registo**
- 3.2 Estratégia de pesquisa e seleção**
- 3.3 Análise bibliométrica (Corpus A)**
- 3.4 Síntese narrativa (Corpus B)**
- 3.5 Síntese: o *gap***

MATERIAIS E MÉTODOS

Este capítulo descreve o que foi construído e como foi avaliado. As três primeiras secções tratam da plataforma: de onde vêm os dados, como foram reconciliados num modelo dimensional único e que métricas se calculam sobre ele. As duas últimas tratam do método de avaliação das *baselines* que os Capítulos 6 e 7 aplicam — o protocolo estatístico e a infraestrutura de reprodutibilidade que garante que cada número citado nesta dissertação pode ser refeito. A matemática de cada instrumento consta do Anexo G; aqui descreve-se o desenho e as decisões que o justificam.

4.1 Fontes de dados e ingestão

O consumo energético de uma unidade processual não existe numa fonte única. Na refinaria de Sines, a informação necessária para o calcular está repartida por três famílias de origens, com resoluções, unidades e responsáveis diferentes, e a primeira decisão de desenho da plataforma foi não escolher uma delas: lê-las todas e reconciliá-las por regras declaradas.

O historiador de processo. O historiador IP21 regista as medições de campo — caudais de combustível e de vapor, carga das unidades, densidades, temperaturas e pressões de *flash*, poderes caloríficos — com resolução horária. O acesso faz-se através da plataforma de dados da refinaria (Dremio), numa vista de negócio horária por *tag* (*ip21_hourly*). A plataforma não consulta o historiador *tag* a *tag*: gera, a partir da tabela de mapeamento (Secção 4.2), a instrução SQL que agrega cada *tag* ao dia com a regra que lhe cabe — soma diária para caudais, média diária para poderes caloríficos e propriedades, média multiplicada por 24 para caudais horários, máximo para indicadores — e devolve o resultado em formato longo (*tag*, ano, mês, dia, valor). A primeira versão gerava uma coluna por *tag* numa única consulta larga e esgotava o tempo limite da plataforma; o formato longo, com uma consulta por regra de agregação, resolveu-o sem perder nenhuma *tag*.

Os balanços mensais. O Processamento de Dados da refinaria mantém dois livros de balanço mensal, com valores diários por referência de medidor: o balanço de produção (BAL_PROD; folhas de medidores e de caudais, em toneladas por mês na coluna mensal e por dia nas colunas diárias) e o balanço de utilidades (BAL_UTIL; medidores em toneladas por hora, vapor por nível de pressão). São a fonte oficial do fecho mensal e a referência contra a qual os relatórios de consumo são emitidos. A leitura é feita por funções de ingestão que percorrem as pastas de rede por ano e mês e extraem, por referência, a série diária. Os dois livros não têm a mesma estrutura: no de produção o primeiro dia do mês está seis colunas à direita do identificador, no de utilidades quatro — e a primeira versão da ingestão, que assumia o desvio do primeiro em ambos, perdia dois dias por mês no vapor e somava zeros nos dois últimos, sub-reportando os três níveis de vapor em 5 a 7%. O erro foi encontrado na validação da Secção 5.2 e é o exemplo do que essa validação existe para apanhar. O balanço de produção fornece ainda a folha de poderes caloríficos diários dos combustíveis sem *tag* própria (*off-gas*, *tail gas*, gás natural, coque), lida com uma guarda de gama física (30 a 30 000 kcal/kg, porque uma etiqueta repetida na folha produzia, sem guarda, um poder calorífico médio de dois milhões) e com propagação do último valor conhecido quando um mês não o traz — registando a origem de cada valor (*bal*, *locf*, *backfill*) para que medido e propagado nunca fiquem indistinguíveis.

A energia elétrica. A eletricidade não tem série diária: existe nos relatórios mensais de envio de cada fábrica, em MWh por unidade, com blocos de consumo e de produção. A ingestão lê esses relatórios com um filtro de nomes canónicos (padrão da fábrica seguido de espaço, sufixo de envio, e uma guarda anti-duplicado por ano, mês e padrão que fica com o ficheiro mais recente), porque um ficheiro de segurança deixado na pasta de leitura — uma versão anterior à revisão de janeiro de 2026 — foi somado ao definitivo durante várias atualizações, duplicando o consumo de quatro unidades. Desde julho de 2026 a ingestão expõe o consumo bruto ao lado do líquido (consumo menos produção): o líquido serve o reporte, o bruto serve a *baseline* e o índice de intensidade, porque uma unidade que produz o que consome não deve aparecer com consumo nulo numa relação com a carga.

Planos de fabrico, densidades e crudes. Os planos de fabrico semanais (folhas Excel no arquivo de planeamento, 2020 em diante) fornecem o *slate* de crudes previsto por período e por unidade; as densidades de rede e as propriedades da carga (densidade, temperatura e pressão de *flash*, rendimento em resíduo) vêm do historiador e das folhas de densidades, com um valor por omissão declarado no mapeamento quando a *tag* não existe — e uma coluna de origem que diz, dia a dia, se o valor foi medido ou assumido.

Inventário e extração. Para congelar o estado das fontes e tornar a plataforma reconstruível fora da rede da refinaria, fez-se em julho de 2026 um inventário completo das origens (cerca de 67 mil ficheiros percorridos, 14 GB) e uma extração das que o modelo consome: 3 862 ficheiros e 988 MB em sete classes — balanço de produção (81 ficheiros mensais,

cobertura completa de novembro de 2019 a julho de 2026), balanço de utilidades (84), eletricidade (708), crudes (434), densidades (426), planos de fabrico (2 076) — com o MD5 de cada ficheiro num manifesto e uma verificação posterior (3 856 iguais, 6 divergências, todas em ficheiros de planos de fabrico de julho de 2024 alterados na origem entre a cópia e a verificação). O modelo do *dashboard* foi serializado por inteiro na mesma data (definição tabular, 159 medidas, 21 consultas de transformação, 32 partições, metadados de reflexão) e as 25 tabelas do modelo foram exportadas em texto. É sobre essa exportação — e não sobre uma ligação viva — que o Capítulo 6 trabalha.

4.2 Modelo dimensional e reconciliação

A plataforma é um modelo tabular em esquema em estrela [29], em modo de importação, com 32 tabelas, 243 colunas, 13 relações e 159 medidas. Três tabelas de factos concentram a informação: energia (FactEnergia_Unified: 200 924 linhas dia×unidade×vetor, de 2020-01-01 a 2026-07-31, 16 unidades, 7 vetores), carga (FactCarga_Unified: 45 408 linhas desde novembro de 2019, com a carga total e os seus componentes por nível de agregação) e propriedades da carga (19 105 linhas, 8 unidades), a que se juntam densidades, planos de fabrico e crudes. As dimensões são o calendário (gerado, até ao dia anterior à atualização), as unidades (16, em três fábricas mais os extras, com o limiar de carga mínima de cada uma e a sua composição em secções), os vetores (fuel gás, vapor a 24, 10 e 3 bar, energia elétrica, coque e outros combustíveis, mais o agregado global), os crudes (56) e duas dimensões de apresentação — janela temporal e métrica — que alimentam os seletores do *dashboard*. Os parâmetros físicos que qualquer cálculo usa vivem em duas tabelas de parâmetros e nunca no código: o poder calorífico de referência do gás natural (11 820 kcal/kg), as entalpias equivalentes dos três níveis de vapor (698, 738 e 758 kcal/kg), a conversão da eletricidade (860,4 Mcal por MWh e um factor de eficiência de conversão de 0,57), o número mínimo de observações para estimar uma *baseline* (30) e, por unidade, o limiar de carga abaixo do qual um dia não é operacional — 18 600 t/d na destilação atmosférica.

A tabela de mapeamento é o contrato. O objeto central do modelo não é um facto, é o mapeamento mestre: 286 linhas, cada uma a ligar uma unidade física, um vetor e um papel (consumo ou produção) a uma origem — uma *tag* do historiador, uma referência de balanço ou as duas — com o factor de unidade do canal de *tags*, um factor de inclusão do canal de balanço (1, 0, -1 ou uma fração de alocação), a *tag* de poder calorífico quando aplicável, datas de vigência e um comentário de qualidade. Das 286 linhas, 235 apontam para o balanço de utilidades e 51 para o de produção; 137 têm também *tag* do historiador; 213 são consumos e 73 produções. Cinco mapeamentos auxiliares (poderes caloríficos, eletricidade, carga por *tags* e por balanço, densidades, propriedades) seguem o mesmo princípio: nenhuma constante de conversão, nenhuma referência de medidor e nenhuma regra de alocação existe fora de uma tabela versionada. Foi esta separação que permitiu corrigir, em julho de 2026, a alocação da produção de vapor entre as duas unidades de

vácuo (24% e 76% a 24 bar; 69% e 31% a 3 bar, fórmulas oficiais do controlo processual) alterando uma coluna e nenhuma linha de código.

Três canais, uma regra de precedência. A energia de cada dia, unidade e vetor chega por até três canais — *tags* do historiador, balanço de produção ou utilidades, e relatórios de eletricidade — e a tabela unificada guarda os três lado a lado antes de escolher. A regra é declarada e por linha: balanço, depois eletricidade, depois *tags*; nunca se mistura um canal com outro na mesma linha, e uma coluna de origem regista qual venceu. Na carga a regra é a mesma (balanço antes de historiador) e os componentes da carga seguem a fonte vencedora. Nos 200 924 registos de energia, 121 828 têm balanço e *tags* em simultâneo — é a redundância que a validação da Secção 5.2 explora —, 42 132 só balanço e 36 964 vêm dos relatórios de eletricidade. Uma quarta coluna, o consumo “sem produção”, é igual ao unificado em todos os vetores exceto na eletricidade, onde usa o bruto: é a coluna que a *baseline* e o índice de intensidade consomem. Os relatórios operacionais e o reporte de emissões continuam no líquido.

O que o modelo não faz. Não imputa: um dia sem valor em nenhum canal fica sem valor, e um valor nulo ou zero do canal de balanço é excluído da estimação de *baselines* enquanto a origem dos zeros fabricados não for resolvida na fonte. Não inclui o gás natural nem o *tail gas* no perímetro de nenhuma unidade, por decisão de âmbito. E trata a eletricidade como o que ela é: uma alocação mensal distribuída uniformemente pelos dias, que o Capítulo 6 mostra não ser uma medição diária.

4.3 Cálculo de métricas energéticas

Uma unidade comum. Todos os vetores são convertidos a toneladas de gás natural equivalente por dia (t GNE/d), a unidade em que a refinaria orçamenta e reporta. Os combustíveis (fuel gás, coque, outros) convertem-se pelo caudal diário multiplicado pelo poder calorífico do dia — lido de uma *tag* horária no fuel gás e no coque, da folha de poderes caloríficos nos restantes — dividido pelo poder calorífico de referência do gás natural. O vapor converte-se pelo caudal multiplicado pela entalpia equivalente do seu nível de pressão; o de 10 bar é um fluxo líquido (consumo menos produção) e pode ser negativo. A eletricidade converte-se de MWh para energia térmica e desta para combustível equivalente pelo factor de eficiência de conversão. Cada regra está declarada na tabela de parâmetros por vetor, e o cálculo é feito uma vez, na ingestão, para que todas as medidas leiam a mesma coluna.

Dia operacional e consumo específico. Um dia é operacional para uma unidade quando a sua carga é igual ou superior ao limiar declarado para essa unidade. O consumo específico é o total de GNE nos dias operacionais dividido pela carga nesses mesmos dias, em t GNE por quilotonelada; as janelas móveis de 7 e 30 dias e o acumulado do período

são calculados sobre a mesma seleção. O limiar não é um parâmetro de apresentação: é a fronteira do domínio em que a *baseline* é estimada, e a Secção 6.2 mostra o que ele exclui.

A *baseline* em produção. Para cada unidade, vetor e ano civil, o modelo estima por mínimos quadrados a relação $E = aQ + b$ (o modelo estatístico de *baseline* que a ISO 50006 tipifica [26]) entre o consumo diário (em t GNE/d, na coluna sem produção) e a carga diária (em kton/d), sobre os dias operacionais do ano com energia não nula e anteriores ao dia corrente. A estimação é feita dentro do próprio modelo, numa tabela calculada que materializa, por célula unidade×vetor×ano, o declive, a ordenada na origem, o desvio-padrão residual, o coeficiente de determinação e o número de observações — 583 células no estado de julho de 2026, incluindo o ano corrente marcado como parcial. O vetor global de cada unidade é a soma dos vetores orçamentáveis (o coque, subproduto queimado no regenerador, mantém reta própria mas fica fora da reta global). Foi esta tabela — exportada tal como o modelo a calcula — que serviu de referência ao gate de replicação da Secção 6.1: o que o Capítulo 6 critica é, com igualdade numérica verificada, o que este parágrafo descreve.

Resíduos, bandas e acumulados. O resíduo diário é a diferença entre o consumo observado e o previsto pela *baseline* do ano de referência selecionado, aplicada à carga do próprio dia; o resíduo padronizado divide-o pelo desvio-padrão residual dessa *baseline*. As bandas a ± 1 , ± 2 e $\pm 3\sigma$ são as do desenho de produção, e a regra de alarme é a saída da banda de $\pm 2\sigma$. Sobre a série de resíduos calculam-se o excesso diário (a parte positiva do resíduo), o excesso acumulado por vetor, unidade e refinaria, a fração de dias acima e abaixo da banda, o desvio médio fora da banda, a soma acumulada dos resíduos desde o início do período selecionado (o gráfico de CUSUM [41] do *dashboard*) e o ritmo de excesso nas janelas de 7 e 30 dias. Um painel de regras de carta de controlo verifica oito regras clássicas de causas especiais, na linha das de Nelson [37], sobre os resíduos padronizados — um ponto fora de $\pm 3\sigma$, dois em três fora de $\pm 2\sigma$, quatro em cinco fora de $\pm 1\sigma$, oito consecutivos do mesmo lado, seis monotónicos, catorze alternados, quinze consecutivos dentro de $\pm 1\sigma$, oito consecutivos fora de $\pm 1\sigma$ — e conta as ocorrências de cada uma. Estas estatísticas descrevem o método em produção; a sua validade estatística é a pergunta do Capítulo 6.

O índice de intensidade energética. Além da *baseline* interna, o modelo calcula por unidade o índice de intensidade energética da metodologia de *benchmarking* da indústria (Solomon): a razão, em percentagem, entre o consumo real em kBTU e uma energia padrão que depende da carga em barris e de um factor por unidade — para a destilação atmosférica, uma função da densidade da carga, do rendimento em resíduo e das condições de *flash*, com um teto para cargas leves — calculada só nos dias operacionais e com todas as propriedades disponíveis. O índice é publicado no dia, em janelas móveis de 7 e 30 dias e

no período, contra as bandas de quartil da unidade, e decomposto por vetor numa cascata. Serve de contexto externo; não é uma *baseline* e não entra na avaliação do Capítulo 6.

Emissões. O equivalente em CO₂ é calculado do consumo líquido por vetor com o factor de emissão declarado na dimensão dos vetores, no dia e acumulado, e apresentado ao lado do GNE em todas as vistas de síntese.

4.4 Protocolo de avaliação estatística das *baselines*

A lição que definiu o protocolo. Uma primeira análise das *baselines*, feita em abril de 2026 fora da plataforma, foi invalidada em agosto: usava um limiar de carga escrito à mão (15 kton/d) em vez do limiar oficial lido da configuração (18 600 t/d), e por isso analisava uma regressão que não era a que está em produção — e concluía coisas que não existem nos dados oficiais. Duas regras saíram daí e não se negociaram depois: nenhum parâmetro de seleção é escrito à mão, todos são lidos das tabelas de configuração do modelo de produção; e replica-se antes de criticar — se os coeficientes recalculados não reproduzem os de produção em todas as células, o protocolo para. Uma terceira regra veio da revisão externa do protocolo: não se criticam violações de independência usando testes que assumem independência e apresentando os seus *p*-values como prova.

Pré-registo e revisão adversarial. O protocolo foi escrito antes de qualquer execução, no sentido do pré-registo [39] — perguntas, estimadores, comparadores, famílias de hipóteses, correção de multiplicidade, limiares e a grelha de sensibilidade — e submetido a quatro revisões adversariais independentes (Anexo F), que apontaram vinte defeitos na primeira versão; a versão 1.2, que se descreve aqui, é a que resultou da adjudicação desses defeitos. Todos os parâmetros vivem num ficheiro de configuração versionado (*params.yaml*); nenhum é duplicado em código. As poucas decisões tomadas depois de ver resultados — sobre desenho, nunca sobre critérios — estão datadas no plano de execução e assinaladas no texto onde entram.

Uma pergunta de dados antes de qualquer análise. O primeiro passo não é estatístico: é um perfil dos dados — cobertura, mecanismo de falta, distribuições brutas, efeito do filtro de seleção, séries temporais, relação bivariada, consistência entre fontes — que uma pessoa lê e aceita, com declaração assinada e ligada por *hash* à corrida que o produziu, antes de qualquer instrumento arrancar. O erro de abril foi um erro de seleção de dados que um perfil decente teria exposto; o gate existe para que isso não volte a acontecer, e o código não tem caminho de escrita para a declaração — só uma pessoa a pode criar.

Replicação exata como gate bloqueante. Sobre a exportação congelada do modelo, o protocolo reestima a regressão anual de cada unidade–vetor com o limiar lido da configuração e compara declive, ordenada na origem, desvio-padrão residual e coeficiente

de determinação com os da tabela de *baselines* exportada, célula a célula, com tolerância pré-registada de 10^{-6} ; a identidade dos dias selecionados é comparada por *fingerprint* do conjunto. Trinta células têm de reproduzir-se; se uma falha, nada a jusante corre. Cada instrumento posterior repete uma guarda de replicação sobre as células que usa.

As perguntas e a inferência. As conclusões do diagnóstico assentam em cinco perguntas, cada uma com estimador, comparador e critério declarados: se o modelo de um ano prevê o seguinte melhor do que referências triviais (média do ano de treino como nulo primário; mesmo dia do ano anterior e média móvel de trinta dias como secundários [24]), medido pela diferença emparelhada de perda absoluta diária [11, 18]; se os declives anuais são iguais, por um teste de Wald sobre uma regressão empilhada com interações ano×carga, na linha do teste de Chow [9]; se a banda de $\pm 2\sigma$ do ano de treino cobre a fração nominal dos dias do ano seguinte; que desvio mínimo o sistema de alarmes deteta e em quanto tempo; e se covariáveis pré-especificadas (densidade da carga, temperatura e pressão de *flash*) acrescentam valor preditivo fora da amostra. A inferência respeita a dependência serial que os próprios resíduos exibem: erros-padrão robustos à heterocedasticidade e à autocorrelação [38] (*kernel* quadrático-espectral com largura de banda de Andrews [2]) para os testes de igualdade, e intervalos percentil [13, 14] por *bootstrap* de blocos móveis [31, 32] — bloco base de $\lceil n^{1/3} \rceil$ dias [17] com desfasamentos civis exatos, 2 000 réplicas, semente fixa, sensibilidade a blocos de 7, 14, 30 e 60 dias — para todos os contrastes de perdas e coberturas. Uma conclusão existe apenas quando o intervalo exclui o valor de referência; nunca por comparação de pontos. A multiplicidade é corrigida dentro da família dos testes de igualdade de declives (Benjamini–Hochberg [4], com Benjamini–Yekutieli [5] como verificação); os restantes resultados são por contraste e são apresentados como tal. A validação do *bootstrap* por simulação, a $\rho = 0,90$ e bloco de 60 dias, deu uma cobertura de 357/400; o resultado foi adjudicado por teste binomial exato [10] depois de conhecido e fica declarado como o que é — ausência de evidência de cobertura inferior a 0,90, não prova de cobertura nominal.

Diagnósticos descritivos. Um segundo conjunto de instrumentos — dependência e variância dos resíduos, distribuição e caudas, segmentação do espaço operacional, sobreposição de suporte entre anos, influência de semanas, plausibilidade física dos coeficientes, correlação entre vetores — documenta mecanismos. O seu estatuto é declarado inferior: os *p*-values são índices descritivos calculados sob independência, nenhum rótulo é conclusão, e nenhuma afirmação da dissertação assenta neles.

Sensibilidade às convenções. Todas as conclusões são reavaliadas numa grelha pré-registada que cruza o limiar de carga a 0,8, 1,0 e 1,2 vezes o oficial com duas partições temporais — anos civis e janelas de doze meses ancoradas a 1 de julho — num total de 624 reavaliações, com a célula de referência a reproduzir exatamente os testes deterministas. A grelha qualifica; nunca cria conclusões.

Demonstração das linhas orientadoras. A avaliação de candidatos alternativos (estimadores robustos, bandas com dependência modelada, critério de aceitação) usa os mesmos cinco pares anuais, com constantes fixadas a priori ou afinadas apenas no ano de treino, e conclusões só por intervalo. A formulação original previa uma partição selada com 2025 intocado; foi substituída, por decisão datada, por validação temporal encadeada [50, 6], porque 2025 já tinha informado o diagnóstico — e nenhum resultado dessa parte se chama *holdout*. O critério de aceitação (conteúdo preditivo e banda suportada, cada um em pelo menos quatro dos cinco pares) foi fixado antes de qualquer resultado.

Referência congelada e simulação. A exploração da Secção 7.5 congela a relação de 2020, a sua escala (por validação cruzada em seis blocos contíguos [6]) e o seu estado inicial, aplica-os a 2021–2025 numa população primária declarada (dias retidos, dentro do suporte de carga de 2020, com observação e predição finitas), compara modelos apenas na interseção dessas populações, e mede o comportamento de *baselines* e monitores com verdade conhecida num gerador declarado (relação de 2020 com as covariáveis de referência, ruído autorregressivo, máscara real de dias admissíveis, limiares calibrados sob a hipótese nula a 5%, quatrocentas réplicas por célula, oito contrastes co-primários declarados antes da execução). Todos os artefactos distinguem, linha a linha, o que foi observado no *snapshot* do que foi imposto em simulação.

4.5 Reprodutibilidade e proveniência

A exigência que estrutura toda a infraestrutura é simples de enunciar: qualquer número citado nesta dissertação tem de poder ser refeito, e tem de ser possível provar que não foi editado depois de produzido [42, 46].

Dados congelados e identificados. As 13 tabelas do modelo dimensional que a avaliação consome foram exportadas em 2026-07-31 e copiadas para o repositório de análise como ficheiros de texto só de leitura; o *hash* SHA-256 de cada um está registado num ficheiro de fontes, e uma corrida cujo *hash* de entrada não coincida falha em vez de produzir números diferentes em silêncio. A identidade das observações seleccionadas pela *baseline* de produção é guardada como *fingerprints* de referência.

Corridas write-once com manifesto. Cada execução de um instrumento é uma corrida: prepara-se numa área de *staging*, verifica-se antes de começar (dados, ambiente, árvore de código limpa) e publica-se por renomeação atómica para uma pasta identificada por data e *hash*, ou para uma pasta de falhas se a verificação final não passar. Nunca se edita uma corrida publicada; uma corrida substituída fica publicada e é apenas deixada de citar. O manifesto de cada corrida regista os *hashes* dos dados de entrada, o *commit* do código, a exigência de que a árvore esteja limpa, as versões exatas do ambiente (dois ambientes fixados por ficheiro de bloqueio, um para a avaliação do método de produção e outro

para a exploração com referência congelada, que não podem ser trocados), as sementes, e o inventário de todos os ficheiros produzidos com o seu SHA-256 e um *hash* do próprio inventário. As interfaces de execução não aceitam parâmetros científicos: só a raiz do repositório e a pasta de saída; tudo o resto é lido da configuração.

Pins e verificação independente. Os resultados que a dissertação cita são corridas canónicas identificadas (“pinadas”) na configuração; qualquer instrumento que consuma resultados de outro lê-os da corrida pinada, verifica o *hash* do manifesto de origem antes de ler e recusa o lote errado. Um verificador que não importa nada do repositório — só as bibliotecas de *hash* e de leitura de texto — recomputa, para cada corrida citada, os *hashes* e tamanhos de todos os ficheiros e o *hash* do inventário. À data desta versão, 110 manifestos e 1 481 ficheiros foram verificados sem divergência por uma auditoria independente.

Números nos documentos. Os relatórios de resultados não contêm números escritos à mão: cada valor da exploração com referência congelada é derivado das tabelas pinadas por um gerador de documentos e registado num bloco de proveniência no fim de cada documento, que um teste automático recalcula e confronta com a prosa. As tabelas dos capítulos de resultados desta dissertação seguem a mesma origem; a Secção 7.7 diz onde a garantia é mais fraca do que o mecanismo sugere.

Testes e ambiente. O código de avaliação tem 1 061 testes na suite do método de produção e 683 na da exploração com referência congelada, cada um no seu ambiente; sem teste, um instrumento não está feito, e um teste que verifica a presença de um campo não verifica o significado do filtro que o produziu — lição registada depois de uma revisão ter apanhado cinco afirmações que a tabela por trás delas refutava. O determinismo é declarado com precisão: as corridas são reproduzíveis no ambiente fixado com igualdade numérica até cerca de 10^{-15} ; a igualdade byte a byte de ficheiros com valores em vírgula flutuante depende da biblioteca de álgebra linear da máquina, e não é prometida.

Trilha adversarial. As revisões externas do protocolo, as auditorias científicas de cada parte (a integridade da cadeia de resultados foi aprovada e a conformidade científica reprovada em setembro de 2026, com correções feitas no código e testes que reproduzem cada achado, e uma segunda reinspeção ainda em curso à data desta versão) e as decisões do autor que delas resultaram estão versionadas no repositório e resumidas no Anexo F. É a parte da metodologia que mais custou e a que mais vale: cinco afirmações da primeira versão dos resultados eram falsas, todas do mesmo tipo — narrativa à frente da verificação —, e nenhuma sobreviveu a abrir a linha da tabela que a devia sustentar.

RESULTADOS I — A PLATAFORMA

O primeiro resultado desta dissertação é um instrumento. Este capítulo descreve o que foi entregue — a arquitetura da plataforma de monitorização energética que está em uso na refinaria —, prova que a camada de dados diz a verdade, apresenta o *dashboard* que a torna legível, e declara o que ficou de fora. Tudo o que o Capítulo 6 conclui sobre as *baselines* é uma consulta ao modelo de dados aqui descrito; se este capítulo falhasse, o seguinte não teria base. A ordem do capítulo é a ordem da confiança: só depois de se ter mostrado que os números batem certo é que faz sentido mostrar como se leem.

5.1 Arquitetura entregue

O que é. A plataforma é um modelo tabular em Power BI — *Energy Performance Monitor*, versão 22, de 31 de julho de 2026 — com um esquema em estrela de 32 tabelas, 243 colunas, 13 relações, 159 medidas e 21 consultas de transformação, que cobre 16 unidades processuais em três fábricas e nos extras (enxofres e *flares*), sete vetores energéticos, resolução diária, de 1 de janeiro de 2020 ao dia anterior a cada atualização. O modelo ocupa 68,7 MB e importa os dados; o historiador é consultado através da plataforma de dados da refinaria, os balanços e os relatórios de eletricidade lidos das pastas de rede onde o Processamento de Dados os mantém, e os planos de fabrico do arquivo de planeamento. As consultas ao historiador são geradas a partir das tabelas de mapeamento no momento da atualização; nenhuma *tag* está escrita no código.

Três decisões que o definem. A primeira é a que a Secção 4.2 descreve: os três canais de origem coexistem na tabela de factos e uma regra de precedência declarada escolhe por linha, com a origem registada — é o que torna a validação da secção seguinte possível, porque um dia com balanço e *tag* em simultâneo é um dia com duas medições independentes da mesma coisa. A segunda é que a *baseline* é materializada no modelo: a tabela de coeficientes por unidade, vetor e ano é calculada uma vez por atualização e as medidas de resíduo, banda e excesso leem-na por pesquisa, em vez de reestimarem a regressão em cada visual — o que tornou o *dashboard* responsivo e, mais importante, tornou a *baseline* exportável e auditável como uma tabela. A terceira é que todos os parâmetros

que um utilizador pode querer mudar — ano de referência da *baseline*, métrica (toneladas, percentagem ou desvios-padrão), janela (último dia, 7 dias, 30 dias, acumulado), unidade, vetor, período — são seletores do modelo e não cópias de páginas: as 159 medidas são genéricas em relação ao contexto de filtro, e a mesma medida serve as quatro páginas.

Como está organizado. As medidas vivem em tabelas de domínio — consumos e conversões gerais, *baselines*, resíduos e bandas, séries temporais e acumulados, índice de intensidade, seletores e cartões — para que quem mantém o modelo encontre cada cálculo pelo que ele faz. Os visuais que o Power BI nativo não oferece (o diagrama de dispersão com banda e cor temporal, o mapa de calor de calendário, a cascata, a matriz de prioridades, os cartões de indicador) são declarados em Vega-Lite ou em HTML dentro do próprio relatório, sem dependências externas, e leem as mesmas medidas. Seis marcadores guardam as vistas de arranque de cada página.

Evolução. A primeira arquitetura, de março de 2026, ligava-se ao historiador por consulta direta, usava um limiar de carga único e estimava a regressão em tempo de consulta; a versão de julho, aqui descrita, importa, lê o limiar de cada unidade da sua dimensão, materializa a *baseline* e reconcilia três canais. Entre as duas versões o mapeamento mestre chegou à sua vigésima segunda revisão, e a validação da secção seguinte motivou a maior parte das últimas.

5.2 Validação da camada de dados

Um *dashboard* que apresenta números errados com confiança é pior do que nenhum *dashboard*. Antes de qualquer visual ser dado por terminado, a camada de dados foi validada a três fontes: para cada unidade, vetor e mês de janeiro a maio de 2026, o valor do *dashboard* foi comparado com o relatório oficial de consumo emitido por cada fábrica (o “Envio”) e com uma reconstrução independente a partir do mapeamento mestre aplicado diretamente às folhas de medidores do balanço — 400 células, com tolerância de 2 t ou 0,2%, o que for maior. As três fontes são, em princípio, três leituras da mesma realidade física; onde discordam, uma delas está errada, e o método existe para descobrir qual.

O ponto de partida. Na versão 13 do mapeamento, 242 células coincidiam, 64 estavam vazias (combinações unidade–vetor sem consumo) e 94 divergiam. O trabalho de julho de 2026 foi explicar as 94, uma a uma, até nenhuma ficar classificada como inconsistente. Ficaram explicadas por sete causas, e o resultado mais instrutivo da validação é onde essas causas estavam: em todas as três fontes.

Erros no motor. O canal de balanço não tinha mecanismo de inclusão: a coluna de factor do mapeamento aplicava-se só ao canal de *tags* (conversão de kg/h para t/h), e as dezoito linhas com factor zero — circuitos internos, medidores partilhados — entravam por inteiro,

enquanto uma linha de crédito (factor -1) não era subtraída. Duas unidades apareciam com o dobro do vapor real (48 461 contra 26 019 t num nível; 160 322 contra 80 696 t noutra, em cinco meses); a correção, uma coluna nova de factor de inclusão para o canal de balanço, moveu 251 kt de vapor em módulo sem tocar no canal de *tags*. Um filtro de nomes de folhas que só aceitava as fábricas excluía as folhas dos enxofres e dos *flares*: essas unidades nunca entravam na tabela, e o mapeamento — que já estava certo — não podia ser validado. Um ficheiro de segurança deixado na pasta de leitura dos relatórios de eletricidade era lido ao vivo e somado ao definitivo, duplicando quatro unidades em janeiro. E, antes destes, o desvio de colunas do balanço de utilidades (Secção 4.1) sub-reportava os três níveis de vapor em 5 a 7% em todas as unidades — o único destes erros que era universal e silencioso.

Erros no mapeamento. Uma referência de medidor em falta na produção de vapor de 3 bar da destilação atmosférica produzia um défice todos os meses — 29,6; 61,1; 33,3; 9,4; 0,8 t — que passava por baixo da tolerância relativa em quatro dos cinco meses; foi encontrada por procura do perfil mensal do défice entre as 481 referências da folha de medidores, com coincidência a 0,1 t nos cinco meses. A alocação da produção de vapor entre as duas unidades de vácuo seguia uma convenção diferente da do controlo processual; das oito fórmulas oficiais, seis foram confirmadas a $\pm 0,5$ t e duas rejeitadas e devolvidas ao controlo processual com a evidência (uma delas referia uma linha de outra versão do ficheiro). Duas referências de fuel gás dos enxofres tinham grafias que nunca existiram na folha — um hífen no sítio errado, uma letra a mais.

Erros na fonte oficial. No relatório cumulativo de uma unidade, um bloco de linhas de fevereiro tinha a coluna colada de maio: produção de vapor a 24 bar 3 264,0 no relatório contra 2 215,4 nas medições; consumo de vapor a 3 bar 1 120,0 contra 2 430,7; energia elétrica 828,9 contra 569,1 MWh. O consumo específico do mês parecia validar o valor colado — porque era recalculado sobre ele com a carga verdadeira, que escapara à colagem; o que o denunciou foi a igualdade ao decimal entre a célula de fevereiro e a de maio. O Processamento de Dados confirmou e corrigiu o relatório; as três células fecharam a três fontes ao decimal. É o episódio que inverte a hierarquia habitual: a “verdade-terreno” estava errada e o *dashboard* certo, e só uma validação com três leituras independentes o podia mostrar.

O fecho. A progressão foi 242 células coincidentes na versão 13, 263 depois do factor de inclusão, 392 de 400 com a versão 15 (327 coincidentes mais 65 vazias), 395 com o relatório de fevereiro corrigido e 400 de 400 com a versão 15.1 — a primeira validação completamente limpa da cadeia, dos relatórios ao motor ao mapeamento. O fuel gás foi validado a duas fontes, por decisão de âmbito, e a ressalva fica escrita: o *dashboard* coincide com o relatório porque ambos leem o mesmo balanço de produção; é consistência entre fontes dependentes, não verificação, e se o balanço vier errado erram os dois sem aviso.

A carga. A carga foi validada por outro caminho: a soma dos componentes de carga de cada unidade contra a linha de carga do balanço, em 118 de 120 células (24 unidades, cinco meses) a $\pm 0,1$ t; as duas que não fecham são definição, não erro — a linha de carga da destilação atmosférica exclui o resíduo atmosférico reprocessado, que em fevereiro valeu 9% da carga do mês. Ficou identificada uma questão que o *dashboard* não resolve sozinho: os relatórios oficiais e o balanço usam duas definições de carga (hidrocarbonetos ao nível do componente, excluindo hidrogénio, limpezas, *quench* e retornos, contra a linha total do balanço), ambas reproduzíveis, e a escolha muda os consumos específicos — 2,4% numa unidade só pelo hidrogénio, um factor de sete noutra. É uma decisão de definição de indicador, registada como pendente e devolvida a quem define o indicador.

O que a validação ensinou. Quatro lições passaram a regras da plataforma. Uma tolerância relativa em números grandes esconde termos pequenos e sistemáticos: o segundo teste obrigatório é a consistência do resíduo — se a diferença tem sempre o mesmo sinal e nunca é nula, é estrutural, por mais pequena que seja. Um filtro de ficheiros por prefixo é uma armadilha (“fábrica I” é prefixo de “fábrica II”); os filtros passaram a exigir o nome canónico completo e a recusar duplicados em vez de os somar. Os ficheiros de segurança nunca ficam na pasta de leitura. E a validação a três fontes não é um passo de projeto: é um teste de aceitação permanente, que a plataforma repete a cada fecho mensal, porque apanhou erros nas três fontes e nenhuma delas, isolada, era fiável.

5.3 O dashboard

O *dashboard* tem quatro páginas, desenhadas como um percurso de diagnóstico: da refinaria para a unidade, da unidade para o vetor, do vetor para a *baseline* que o julga. Todas partilham o cabeçalho — métrica, janela, ano e mês, ano de referência da *baseline*, data da última atualização — e a mesma semântica: um desvio é sempre medido contra a *baseline* do ano de referência selecionado, aplicada à carga do próprio dia, e é positivo quando o consumo excede o previsto.

Vista comparativa da refinaria. A primeira página responde à pergunta da reunião da manhã: onde olhar primeiro. Uma matriz de semáforos cruza as 16 unidades com os seis vetores e mostra o desvio na métrica e janela escolhidas, distinguindo “sem vetor”, “sem *baseline*” e “sem dados na janela”; um cartão de extremos identifica a melhor e a pior unidade e o melhor e o pior par unidade–vetor; um gráfico de barras ordena as unidades pelo desvio; um diagrama de Pareto por par unidade–vetor mostra que poucos pares concentram o excesso acumulado; um cartão de excesso acumulado dá o total do período, o ritmo a 7 e a 30 dias contra a *baseline*, e as unidades que mais contribuem; a tendência mensal do excesso da refinaria contra a *baseline* mensal; um cartão dos piores e melhores dias do período com o par dominante em cada um; e um cartão de qualidade das *baselines* do ano de referência — coeficiente de determinação médio, contagem de relações

adequadas, marginais e inadequadas, e a qualidade por unidade. Este último cartão é a primeira forma em que o diagnóstico do Capítulo 6 entrou na plataforma: ainda antes de qualquer teste, mostra ao utilizador que a maioria das relações com a carga explica pouco.

Detalhe da unidade. A segunda página fixa uma unidade e mostra os seus vetores: cartões de melhor e pior vetor, índice de intensidade, GNE total e específico do dia e acumulado do período com variação face à *baseline*, CO₂ equivalente, e excesso acumulado decomposto por vetor com o seu ritmo. Um gráfico de linhas sobrepõe o consumo total ao consumo específico com as médias móveis de 7 e 30 dias; um gráfico de barras a 100% mostra, por vetor, a fração de dias abaixo e acima da banda de $\pm 2\sigma$; um mapa de calor de calendário — um quadrado por dia, colorido pelo resíduo padronizado — torna visíveis os períodos persistentes e as sequências, com uma sobreposição opcional do plano de fabrico para ligar os dias a campanhas; e uma matriz de prioridades coloca cada vetor num plano de fração de dias em alarme contra desvio médio fora da banda, com o tamanho proporcional ao excesso acumulado. É a página que responde “qual vetor, e há quanto tempo”.

Índice de intensidade. A terceira página apresenta o índice de intensidade energética da unidade (Secção 4.3) no dia e nas janelas de 7 e 30 dias, sobre as bandas de quartil da indústria; os cartões de índice atual e médio, do factor padrão da unidade, do quadrante e do peso da unidade no índice da refinaria; uma cascata que decompõe o índice por vetor e pela *baseline*; e o consumo real contra a energia padrão dia a dia, com o contexto de carga e de qualidade da *baseline* ao lado. Serve para situar a unidade face a uma referência externa que a refinaria já usa; não substitui a *baseline* interna nem foi objeto do diagnóstico.

Baselines e diagnóstico. A quarta página é a que a avaliação do Capítulo 6 tomou como objeto. Para um vetor, uma unidade e um ano de referência: o diagrama de dispersão do consumo contra a carga, com a reta estimada, a banda de $\pm 2\sigma$ e os pontos coloridos pelo tempo, do mais antigo ao mais recente; um cartão de estatísticas com a equação, o coeficiente de determinação no ano de referência e no período, o desvio-padrão residual, a fração de dias acima e abaixo da banda; um painel com as oito regras de carta de controlo e o número de ocorrências de cada uma, o total de dias limpos e com violação e a regra dominante; a soma acumulada dos resíduos desde o início do período, com o ritmo a 7 e a 30 dias, que mostra um desvio persistente antes de a banda diária o assinalar; e os resíduos padronizados no tempo com as bandas de 1, 2 e 3 desvios-padrão, ou, por alternância, o consumo observado contra o previsto. No estado de julho de 2026, para o fuel gás da destilação atmosférica com referência em 2024, o painel mostrava sete das oito regras violadas e 124 dias em 295 com pelo menos uma violação, a regra dominante a ser oito dias consecutivos do mesmo lado — o retrato, já visível no instrumento, do que o Capítulo 6 mede com inferência adequada.

O que a monitorização passou a permitir. Antes da plataforma, o consumo por unidade e vetor existia em relatórios mensais por fábrica, fechados algumas semanas depois do mês, sem normalização pela carga e sem comparação entre unidades além da leitura manual. Com ela, o mesmo consumo está disponível ao dia, para as 16 unidades e os sete vetores, com a carga, a *baseline*, o resíduo e o acumulado no mesmo lugar, e com a proveniência de cada valor registada — que canal o forneceu, e se um poder calorífico ou uma propriedade foi medido ou assumido. A pergunta “esta unidade consome mais do que devia?” passou a ter uma resposta consultável; a pergunta seguinte — se essa resposta é estatisticamente válida — é a do capítulo seguinte.

5.4 Cobertura e limitações da plataforma

O que está dentro. Dezasseis unidades processuais, sete vetores, seis anos e sete meses de história diária, três canais reconciliados, *baselines* por ano e vetor materializadas e exportáveis, índice de intensidade por unidade, planos de fabrico desde 2020 e propriedades da carga onde o historiador as tem.

O que ficou de fora, por decisão. O gás natural e o *tail gas* não entram no perímetro de nenhuma unidade. O coque, por ser subproduto queimado no regenerador e não combustível orçamentável, tem *baseline* própria mas fica fora do agregado global. As secções sem casa própria no *dashboard* (as secções auxiliares agregadas na composição de cada unidade) contam para a unidade que as contém, com a composição declarada na dimensão. Os *flares* não têm *baseline*, porque não têm carga.

O que ficou de fora, por limitação dos dados. A energia elétrica é uma alocação mensal distribuída uniformemente pelos dias: qualquer leitura diária dela é uma leitura do mês, e o Capítulo 6 trata-a como tal. Uma parte das *tags* do historiador referidas no mapeamento está anotada como “a verificar” e o valor correspondente vem do balanço; onde uma propriedade da carga não tem *tag*, o modelo usa o valor por omissão declarado e regista-o como assumido. Os poderes caloríficos sem *tag* são propagados do último valor conhecido quando um mês não os traz, com a origem registada. A resolução é diária: transientes de arranque, perturbações de turno e alterações rápidas de utilidades não são visíveis — o instrumento é tático e supervisorio, não de sala de controlo. Não há calendário operacional integrado (paragens, arranques, intervenções), o que o plano de fabrico sobreposto ao calendário mitiga mas não substitui; a consequência para a avaliação está na Secção 6.6.

O que a validação deixou aberto. A definição de carga para os indicadores (com ou sem resíduo reprocessado; hidrocarbonetos ao nível do componente ou linha total do balanço) é uma decisão pendente que muda os consumos específicos; duas fórmulas de alocação foram devolvidas ao controlo processual; o fuel gás está validado a duas fontes

dependentes; e o mecanismo de zeros fabricados no canal de balanço, que a estimação de *baselines* exclui por filtro, continua por resolver na fonte.

O que o instrumento não decide. A plataforma mostra desvios face a uma *baseline*; não diz se a *baseline* é válida, nem se um desvio é ineficiência. A primeira pergunta é a do Capítulo 6; a segunda exige informação que a refinaria tem e a plataforma ainda não recebe — eventos operacionais, rótulos, margens de materialidade — e a Secção 7.6 diz como o desenho fica preparado para a receber.

RESULTADOS II — DIAGNÓSTICO DAS BASELINES

Este capítulo responde à segunda questão de investigação: as baselines energéticas em produção na unidade de destilação atmosférica são válidas para os fins que a ISO 50006 lhes atribui — normalizar o consumo pela carga, sustentar a comparação de desempenho entre períodos e alimentar um sistema de alarmes? A análise executa-se integralmente sobre o modelo de dados validado no Capítulo 5: cada resultado é uma consulta ao mesmo esquema dimensional que alimenta o dashboard, e não a um extrato paralelo preparado para o efeito.

O capítulo segue a ordem das perguntas que o protocolo de avaliação (Secção 4.4) fixou antes de qualquer execução: o modelo replica-se? Os dados sustentam-no? Prevê melhor do que referências triviais? Os seus parâmetros são estáveis de ano para ano? A banda de alarme está calibrada? Que desvios consegue detetar? A carga chega como variável explicativa? Cada uma destas perguntas foi respondida com inferência que respeita a dependência serial dos resíduos — erros-padrão HAC e *bootstrap* de blocos móveis — e só delas se extraem conclusões. Um conjunto de diagnósticos descritivos (Secção 6.8) documenta os mecanismos por trás dos resultados; a sua inferência clássica fica explicitamente desqualificada pela autocorrelação residual que os próprios diagnósticos medem, e nenhuma conclusão do capítulo assenta num p -value dessa origem. As definições formais de cada estatística constam do Anexo G; aqui fica apenas o necessário para ler o resultado.

6.1 O modelo sob análise: replicação exata

Antes de qualquer crítica, o método de produção foi replicado de forma exata a partir das tabelas de configuração oficiais: para cada um dos cinco vetores energéticos e cada ano civil de 2020 a 2025, a regressão $E = aQ + b$ foi reestimada sobre os dias com carga acima do limiar oficial de 18 600 t/d — lido da configuração do modelo dimensional, nunca fixado no código — e comparada com os parâmetros em produção. As 30 células vetor-ano reproduzem declive, ordenada na origem, $\hat{\sigma}$ e R^2 oficiais dentro da tolerância pré-registada de 10^{-6} , com erro máximo observado da ordem de 10^{-10} ; os *fingerprints* dos conjuntos de dias seleccionados coincidem célula a célula no *snapshot*. Uma limitação fica declarada

desde já: com o modelo Power BI original já inacessível, a identidade das observações selecionadas é inferida da equivalência numérica e dos *fingerprints*, não demonstrada por verificação independente contra a fonte (mecanismo e limitações na Secção 4.5).

O ponto não é informático, é epistémico: tudo o que as secções seguintes afirmam refere-se, com igualdade numérica verificada, ao modelo que está efetivamente em produção — os mesmos parâmetros que desenham as bandas de alarme do dashboard — e não a uma reconstrução aproximada dele.

6.2 Perfil dos dados e domínio de validade

O painel analisado cobre 2 403 dias candidatos entre 2020-01-01 e o corte oficial de 2026, com 11 955 observações série–dia nos cinco vetores; a falta de dados é rara e concentrada (60 observações, em dois blocos de 30 dias na energia elétrica, 2021-11 e 2026-07). Três características dos dados, estabelecidas antes de qualquer inferência, condicionam a leitura de todo o diagnóstico.

O limiar de carga define um domínio de validade não declarado. O limiar oficial de 18 600 t/d remove 251 dos 2 403 dias candidatos (10,4%) e 744 das 11 467 observações com energia medida. Os dias removidos não são uma franja aleatória de dias atípicos: comparados com os retidos, diferem de forma sistemática em todas as variáveis observadas — diferenças padronizadas de médias com mediana $|SMD| = 2,17$ e máximo 10,5 no consumo energético, e máximos de 19,7 na temperatura de *flash* e 6,8 na pressão de *flash*. Trata-se de outro regime operativo, não de uma cauda da mesma distribuição. A consequência é estrutural: a baseline em produção só descreve a unidade em regime de carga alta, e todo o comportamento abaixo do limiar — arranques, reduções de carga, operação degradada — está fora do domínio em que o modelo alguma vez foi estimado. Este domínio de validade implícito não está declarado em nenhum documento do método de produção, e a sua existência é a primeira condição de uso que o diagnóstico regista. Nos cenários de sensibilidade com o limiar a $\pm 20\%$, a remoção varia entre 187 e 397 dias, com o mesmo padrão de diferenças sistemáticas.

A energia elétrica não é uma medição diária. Nos 77 meses completos do período, o valor diário da energia elétrica é constante dentro de cada mês em 77 — um total mensal distribuído uniformemente pelos dias, não uma medição com resolução diária. Isto explica mecanicamente o R^2 residual do vetor ($\approx 4 \times 10^{-4}$ na configuração oficial): a regressão diária tenta explicar com a carga uma variável que, por construção, não varia dentro do mês. Mais importante, torna o alarme diário da energia elétrica estruturalmente cego: nenhum desvio com duração inferior a um mês é detetável, qualquer que seja a estatística usada. Por esta razão, a energia elétrica é excluída de todas as análises de resolução diária e avaliada apenas por um diagnóstico mensal próprio.

Os resíduos são fortemente dependentes. A autocorrelação residual de primeira ordem das regressões oficiais situa-se entre 0,46 e 0,90 consoante o vetor e o ano completo (medição sistemática na Secção 6.8). Sob esta dependência, os erros-padrão clássicos e os p -values dos testes de diagnóstico habituais deixam de ser fiáveis, e a banda de alarme $\pm 2\hat{\sigma}$ deixa de ter a cobertura nominal que o seu desenho pressupõe. É este facto — medido nos próprios dados — que justifica a maquinaria inferencial do protocolo (Secção 4.4) e que as Secções 6.4 e 6.5 traduzem em consequências operacionais.

6.3 Poder preditivo contra referências triviais

A primeira pergunta é a mais elementar: os parâmetros oficiais de um ano de treino y , aplicados sem reestimação ao ano seguinte $y+1$, prevêm o consumo melhor do que referências triviais? A referência primária é a média do ano de treino — um “modelo” sem carga, que responde sempre o mesmo valor. O efeito primário é a diferença emparelhada de perda absoluta diária, $\Delta_{MAE} = MAE_{nulo} - MAE_{modelo}$, com intervalo de confiança percentil a 95% por *moving-block bootstrap* (MBB) sobre a série das diferenças de perda; o *skill* associado é $1 - MAE_{modelo}/MAE_{nulo}$. Não se constrói nenhum teste agregado sobre os cinco pares anuais: cada par vetor-transição é reportado individualmente, e a conclusão é o padrão dos intervalos. O ano incompleto de 2026 é apenas diagnóstico.

O resultado divide os vetores em dois grupos. O fuel gás tem conteúdo preditivo real: em quatro das cinco transições completas (2020→2021, 2022→2023, 2023→2024, 2024→2025) o *skill* situa-se entre 0,30 e 0,40 e o intervalo MBB de Δ_{MAE} exclui zero do lado positivo; a exceção é 2021→2022 (*skill* 0,06, intervalo contém zero). Conhecer a carga vale, nas transições favoráveis, reduções de 30–40% do erro absoluto médio face a responder sempre a média.

Os três vetores de vapor são, para efeitos de previsão pontual, modelos vazios. No vapor de 24 bar o *skill* nunca sai do intervalo $[-0,05; 0,01]$; no de 10 bar, de $[-0,07; 0,004]$; os intervalos ora contêm zero ora o excluem por margens sem significado prático ($|\Delta_{MAE}|$ até 0,5 ton GNE/d, contra consumos médios de dezenas de toneladas). O vapor de 3 bar acrescenta instabilidade de sinal: a transição 2020→2021 é confirmadamente *pior* do que a média do treino (*skill* $-0,20$, intervalo exclui zero do lado negativo), 2021→2022 e 2023→2024 marginalmente melhores, as restantes indistinguíveis de zero. Em três dos quatro vetores diários, a componente linear em Q não transporta informação utilizável de um ano para o seguinte — coerente com os R^2 oficiais destes vetores, entre 2×10^{-5} e 0,31.

Duas leituras que o resultado *não* autoriza. Primeiro, previsão pontual não é normalização: um *skill* nulo mata o uso da baseline como preditor, mas não decide por si só o seu valor como normalizador de consumo pela carga — essa avaliação pertence às Secções 6.4 e 6.5. Segundo, o diagnóstico de 2026 (parcial) mostra o fuel gás com *skill* $-0,45$ — o modelo de 2025 é, no ano corrente, substancialmente pior do que a média histórica — mas o ano incompleto não suporta conclusões; o padrão é retomado na análise de estabilidade.

As referências secundárias completam o quadro sem o alterar. Contra o mesmo dia civil do ano anterior, a baseline ganha em 17 dos 20 pares — derrotar uma referência sazonal fraca é fácil. Contra uma média móvel civil de 30 dias, o quadro inverte-se: a média móvel prevê melhor do que a baseline em todos os cinco pares do vapor de 24 bar e do de 3 bar e em quatro dos cinco do de 10 bar, e só no fuel gás a baseline lhe leva vantagem confirmada, em dois pares. A conclusão depende, portanto, do comparador — e a leitura correta é estreita: uma média com informação recente prevê o dia seguinte melhor do que uma relação anual com a carga, o que mede a pobreza preditiva de Q nos vapores, não a superioridade da média móvel como referência de monitorização. Uma média adaptativa incorpora um desvio persistente como “normal” — exatamente o oposto do que se pede a uma baseline de eficiência (Capítulo 7). As tabelas completas constam do Anexo D. O diagnóstico mensal da energia elétrica, contra nulos apropriados à sua resolução (média mensal do treino, mês homólogo, mês anterior), é igualmente remetido para o anexo: com $n=12$ meses por ano e alocação uniforme, nenhuma comparação sustenta uma conclusão.

6.4 Estabilidade dos parâmetros

A recalibração anual do método de produção pressupõe que cada ano de dados reestima *a mesma* relação física entre energia e carga, a menos de ruído amostral. Este pressuposto foi testado diretamente: uma regressão empilhada 2020–2025 com interações ano×carga, e um teste de Wald de igualdade dos declives com covariância HAC (*kernel* quadrático-espectral, largura de banda de Andrews), que permanece válido sob a dependência residual medida na Secção 6.2. Os quatro testes de declive formam uma família com correção de Benjamini–Hochberg (BH), com Benjamini–Yekutieli (BY) como verificação conservadora; os testes de nível formam família separada e secundária.

Tabela 6.1: Teste de Wald HAC de igualdade dos declives anuais, 2020–2025. Família de quatro hipóteses; q -values BH e BY. Declives anuais extremos em ton GNE/d por kton de carga.

Vetor	$\hat{a}$ mín.–máx.	W	p	q_{BH}	q_{BY}
Fuel gás	8,19 – 11,75	12,3	0,031	0,042	0,087
Vapor 24 bar	–0,15 – 0,31	2,8	0,731	0,731	1
Vapor 10 bar	–0,43 – 0,15	13,8	0,017	0,034	0,071
Vapor 3 bar	–0,15 – 2,81	28,0	$3,7 \times 10^{-5}$	$1,5 \times 10^{-4}$	$3,1 \times 10^{-4}$

A igualdade dos declives é rejeitada a 5% sob BH em três dos quatro vetores — vapor de 3 bar, vapor de 10 bar e fuel gás (Tabela 6.1); sob a verificação BY, robusta a qualquer estrutura de dependência entre os testes, sobrevive a rejeição do vapor de 3 bar. Os números por trás dos testes mostram a dimensão física do problema. No vapor de 3 bar o declive oficial percorre $+2,35 \rightarrow +2,81 \rightarrow +1,78 \rightarrow -0,15 \rightarrow +0,73 \rightarrow +0,09$: a “mesma” relação muda de sentido — em 2023, mais carga significava *menos* vapor de 3 bar. No fuel gás, o declive desce de 11,75 para 8,19 entre 2020 e 2024 (–30%), com a ordenada

na origem a subir de -34 para $+96$ ton GNE/d em compensação. No vapor de 10 bar o declive oscila em torno de zero entre $-0,43$ e $+0,15$. A não-rejeição no vapor de 24 bar não é evidência de uma relação estável: com declives anuais entre $-0,15$ e $+0,31$ em torno de zero, o que é estável é a *ausência* de relação — o teste não distingue seis estimativas da mesma constante de seis estimativas de nada. A família secundária dos níveis rejeita a igualdade nos mesmos três vetores, mesmo sob BY.

A leitura operacional: a recalibração anual não está a reestimar uma constante física com precisão crescente; está a ajustar, a cada janeiro, um modelo diferente ao regime desse ano — absorvendo silenciosamente no par (a, b) a deriva que um sistema de monitorização deveria expor. As predições em cargas de referência com bandas de confiança HAC, por vetor e ano, traduzem esta instabilidade em unidades de consumo e constam das figuras deste capítulo; a sensibilidade à largura de banda HAC (multiplicadores $0,5\times$ e $2\times$) não altera nenhuma das conclusões. A rota de sensibilidade por *bootstrap* residual sob a hipótese nula qualifica-as, no entanto: com blocos de 60 dias, nenhum dos testes de declive mantém $p < 0,05$ mesmo antes de ajustamento — as rejeições dependem da resolução temporal assumida para a dependência, e essa discordância entre rotas é reportada como parte do resultado, não escondida escolhendo a rota conveniente. O que fica estabelecido não é, por isso, uma lista de vetores “instáveis” robusta ao método: é que a relação anual entre energia e carga não é invariante, e que o veredicto sobre cada vetor depende de forma mensurável de como se modela a dependência — e, como a Secção 6.9 mostra, de onde se faz começar o ano.

6.5 Calibração das bandas de alarme

O sistema de alarmes em produção declara um dia anómalo quando o resíduo sai da banda $\pm 2\hat{\sigma}$ do ano de treino. Se os pressupostos do desenho valessem — resíduos independentes, homocedásticos, aproximadamente normais, relação estável — a banda aplicada ao ano seguinte cobriria cerca de 95,4% dos dias. A cobertura efetiva foi medida nos cinco pares treino→aplicação completos de cada vetor diário, com intervalo de confiança MBB a 95%; a referência de 0,954 é indicativa, e todas as conclusões resultam da sua exclusão pelo intervalo, nunca da comparação de pontos. O intervalo binomial clássico, que assume independência, é publicado apenas como contraste: o intervalo MBB é 1,0 a 2,3 vezes mais largo em todos os 20 pares — a dependência serial a cobrar o seu preço à precisão.

A descalibração é generalizada e heterogénea. Em sete dos 20 pares a referência é excluída por baixo (sub-cobertura, excesso de alarmes): fuel gás 2020→2021 (cobertura 0,62), vapor de 10 bar 2020→2021, 2021→2022 e 2024→2025 (0,87, 0,88, 0,53) e vapor de 3 bar 2021→2022, 2022→2023 e 2024→2025 (0,38, 0,84, 0,64). Em três pares é excluída por cima (sobre-cobertura, alarme adormecido): fuel gás 2021→2022 (0,98), vapor de 10 bar e vapor de 3 bar 2023→2024 (0,99 e 0,997 — um e um alarme em 364 dias, respetivamente). O vapor de 24 bar fica dentro do intervalo nos cinco pares, em coerência com a Secção 6.4: a banda de um modelo sem relação a proteger é uma banda em torno de uma média, e

essa calibra razoavelmente.

Os casos extremos merecem tradução operacional. No vapor de 3 bar 2021→2022, cobertura 0,38 significa que 62% dos dias do ano estiveram em alarme — um sistema que grita dois dias em cada três não está a monitorizar, está desligado na prática. No vapor de 10 bar 2024→2025, 139 dos 295 dias (47%) excederam a banda; no par seguinte do mesmo vetor (2023→2024) tinham sido 2 em 364. A mesma regra de alarme, no mesmo vetor, oscila entre o silêncio quase total e o ruído permanente consoante o par de anos — consequência direta da instabilidade dos parâmetros e da dependência residual que o desenho da banda ignora. O diagnóstico parcial de 2026 aponta na mesma direção, sem sustentar uma conclusão: no vapor de 10 bar, a banda de 2025 cobre 6% dos dias decorridos — 172 alarmes em 183 dias. A direção importa: é um colapso por *sobrepresvisão* — a média observada na amostra parcial de 2026 (6,5 t GNE/d) fica muito abaixo da predição média da baseline de 2025 (14,4). O nível, que tinha subido até 2025 (Secção 6.4), inverteu nesta amostra; a data e a causa da alteração não estão identificadas, e a análise de estabilidade, que termina em 2025, nada afirma sobre 2026.

Duas qualificações completam o quadro. Primeiro, a sensibilidade aos blocos: das sete sub-coberturas confirmadas, três das mais moderadas (vapor de 10 bar 2020→2021 e 2021→2022, vapor de 3 bar 2022→2023) deixam de excluir a referência com blocos de 30–60 dias; as falhas grandes — fuel gás 2020→2021, vapor de 10 bar 2024→2025, vapor de 3 bar 2021→2022 e 2024→2025 — resistem a todos os comprimentos declarados. Segundo, a cobertura marginal esconde falhas localizadas: no vapor de 10 bar 2024→2025, o segundo semestre cobre apenas 14% dos dias; no fuel gás 2020→2021, o défice concentra-se no primeiro semestre (43%). Uma média anual compatível com a referência pode coexistir com subperíodos francamente descalibrados.

O quadro que emerge das duas últimas secções é consistente: as bandas falham nas duas direções, e falham mais nos vetores onde os parâmetros são mais instáveis. A análise de cobertura condicional completa (tercis de carga por semestre), a distribuição das rajadas de alarme e o erro de forma da banda constante face ao intervalo de predição clássico — um comparador homocedástico e iid, não uma banda robusta validada — constam do Anexo D.

6.6 Detetabilidade

A pergunta seguinte do protocolo é que desvio mínimo de consumo o sistema de alarmes consegue detetar, e ao fim de quantos dias, comparando a regra $\pm 2\hat{\sigma}$ em produção com alternativas sequenciais (CUSUM sobre inovações) para tamanhos de desvio elicitados com o orientador industrial. A pergunta é central para um sistema de monitorização — de nada serve uma banda calibrada que só deteta desvios de uma magnitude que nunca ocorre — mas não é estimável neste conjunto de dados, e o resultado publica-se como tal, em vez de se publicar uma resposta fabricada.

A razão é estrutural. Avaliar detectabilidade exige janelas de referência comprovadamente limpas — períodos em que se saiba, por informação independente das séries, que a unidade operou sem eventos — e a marcação dos eventos reais contra os quais medir tempos de detecção. Ambas dependem do calendário operacional da unidade (paragens, arranques, campanhas, intervenções), pedido em 2026-08-18 e confirmado indisponível em 2026-08-25. Inferir as paragens a partir das próprias séries de consumo, como atalho, contaminaria circularmente o exercício: os “eventos” seriam definidos pela mesma estatística cuja capacidade de detecção se pretende medir. Pela mesma causa raiz ficam não estimáveis o diagnóstico descritivo de eventos operacionais e a componente pós-arranque da análise de suporte. A indisponibilidade fica declarada como limitação (Secção 7.7); o desenho completo da análise permanece especificado no protocolo, executável no dia em que o calendário exista. O Capítulo 7 retoma a pergunta pela única via que não depende do calendário — simulação com verdade conhecida — e diz o que essa via pode e não pode responder.

O que as secções anteriores já mostram, sem substituir esta análise: um sistema cuja cobertura efetiva oscila entre 0,38 e 0,997 consoante o vetor e o par de anos (Secção 6.5) não tem uma curva de detecção única — tem uma por regime de descalibração, e nenhuma delas é a nominal.

6.7 Suficiência da variável explicativa

Se a carga sozinha explica pouco (Secção 6.3), acrescentar variáveis de processo resolve? A resposta usa a única forma de resposta que não se auto-engana: valor preditivo *incremental*, estritamente fora da amostra. Para cada vetor diário e ano de treino, estimam-se dois modelos encaixados — $E = aQ + b$ e $E = aQ + \gamma'Z + b$, com Z pré-especificado antes de qualquer execução (densidade da carga, temperatura e pressão de *flash*; o grau API é excluído por ser transformação determinista da densidade) — e comparam-se as perdas absolutas no ano seguinte, sem reestimação. O efeito é a diferença emparelhada $\Delta_{MAE} = MAE_Q - MAE_{Q+Z}$ com intervalo MBB a 95%: positivo com exclusão de zero, as covariáveis acrescentam; negativo, prejudicam. O ajustamento dentro da amostra — que na soma dos quadrados melhora por construção ao acrescentar regressores — não entra no critério.

O resultado (Tabela 6.2) desautoriza as duas respostas simples. As covariáveis não são inúteis: no vapor de 10 bar acrescentam valor confirmado em quatro das cinco transições, com reduções de erro entre 2% e 18% e nenhum par negativo — o único caso em que o degrau multivariado que a ISO 50006 sanciona teria ajudado de forma consistente, ainda que dois desses ganhos percam a exclusão de zero em blocos de 30–60 dias. Mas também não são um remédio: no fuel gás, o vetor com melhor modelo em Q , as covariáveis *pioram* a previsão em duas transições com exclusão de zero — na transição 2024→2025 o erro absoluto médio agrava-se 32% — e no vapor de 24 bar prejudicam em quatro das cinco. O vapor de 3 bar exhibe o padrão mais instrutivo: ganhos confirmados de

Tabela 6.2: Valor preditivo incremental das covariáveis pré-especificadas: $\Delta_{MAE} = MAE_Q - MAE_{Q+Z}$ em ton GNE/d, por transição treino→aplicação. Marcas: ⁺ intervalo MBB a 95% exclui zero pelo lado positivo (covariáveis confirmadamente úteis); ⁻ exclui zero pelo lado negativo (confirmadamente prejudiciais); sem marca, o intervalo contém zero.

Vetor	20→21	21→22	22→23	23→24	24→25
Fuel gás	4,16 ⁺	-3,65 ⁻	-1,05	-0,66	-7,09 ⁻
Vapor 24 bar	-0,18 ⁻	-0,33 ⁻	-1,09 ⁻	-0,60 ⁻	0,26 ⁺
Vapor 10 bar	0,09 ⁺	1,31 ⁺	0,17	0,32 ⁺	0,36 ⁺
Vapor 3 bar	-0,01	0,05	-4,18 ⁻	8,26 ⁺	0,83 ⁺

+42% em 2023→2024 — robusto a todos os blocos testados — e +10% em 2024→2025, prejuízo confirmado em 2022→2023, nada nos dois primeiros pares — o mesmo conjunto de covariáveis oscila entre valioso e nocivo consoante o par de anos.

Duas cautelas de interpretação. Primeiro, as perdas forward são compatíveis com coeficientes γ pouco transportáveis entre regimes — os próprios coeficientes estimados mudam de sinal entre anos de treino — mas o contraste não identifica a causa: sobreajuste, alteração operacional, deslocação do suporte das covariáveis (Secção 6.8) e variáveis omitidas são explicações concorrentes que estes dados não separam. Segundo, melhor MAE não é melhor monitorização: no caso mais favorável, o vapor de 10 bar em 2024→2025, o modelo aumentado reduz o erro médio em 6% mas a cobertura da respetiva banda *desce* de 53% para 48% — a melhoria na métrica pontual não repara a banda. A consequência prescritiva, desenvolvida no Capítulo 7: a admissão de covariáveis numa baseline não pode ser decisão de catálogo — exige demonstração forward caso a caso com critérios que incluam a banda, e a análise de sensibilidade da Secção 6.9 mostra que mesmo o caso favorável do 10 bar é menos sólido do que esta tabela sugere. A comparação secundária de cobertura das bandas dos dois modelos e os coeficientes estimados constam do Anexo D.

6.8 Diagnósticos complementares

Um conjunto de diagnósticos descritivos fecha o capítulo documentando os mecanismos por trás dos resultados anteriores. O seu estatuto é deliberadamente inferior: todos os *p*-values desta secção são índices descritivos calculados sob pressupostos de independência que os próprios diagnósticos mostram serem falsos, e nenhum rótulo aqui é conclusão. As tabelas completas constam do Anexo D; esta secção destaca os quatro resultados que sustentam ou contextualizam as secções anteriores.

A dependência residual é universal e forte. Medida sistematicamente sobre os resíduos das regressões oficiais, a autocorrelação de primeira ordem em desfaseamento civil situa-se entre 0,45 e 0,90 nos 24 anos-vetor completos (estatística de Durbin–Watson entre 0,15 e 1,08), com os valores mais altos e menos variáveis no vapor de 3 bar (0,76–0,90) — confirmando, vetor a vetor e ano a ano, o perfil preliminar da Secção 6.2. A estrutura de

variância acompanha, com heterogeneidade: os índices descritivos de heterocedasticidade (Breusch–Pagan, ARCH em desfasamentos civis) são elevados em muitas células e quase nulos noutras, e o desvio móvel de 30 dias oscila, dentro do mesmo ano, por fatores que a banda constante $\pm 2\hat{\sigma}$ não acomoda. A sazonalidade mensal existe mas é modesta em quota de variância (η^2 entre 0,03 e 0,09) — estrutura temporal omitida, não explicação dominante. Este bloco é o fundamento empírico de toda a maquinaria HAC/MBB do capítulo: não foi uma preferência metodológica, foi uma imposição dos dados. Regista-se ainda que a autocorrelação dos três vapores sobe ao longo do período — no de 24 bar, de 0,46 em 2021 para 0,89 no parcial de 2026; no de 10 bar, de 0,48 em 2022 para 0,86 —, enquanto o fuel gás se mantém em torno de 0,6: estrutura temporal a migrar progressivamente para o resíduo, coerente com a instabilidade de nível das Secções 6.4 e 6.5.

Nenhuma segmentação em regimes é validável a partir dos dados. No espaço operacional padronizado (carga e covariáveis), o melhor agrupamento *k-means* é $k=2$ com *silhouette* 0,35 — fraco — e o DBSCAN pré-parametrizado devolve um único *cluster* com 71 dias de ruído (3,6%). A leitura exige simetria: estes métodos não validam uma segmentação operacional, mas também não demonstram a inexistência de regimes — o *k-means* força partições e o DBSCAN depende da parametrização. O que fica estabelecido é negativo e útil: a instabilidade dos parâmetros (Secção 6.4) não é o artefacto de regimes óbvios que uma segmentação simples separaria, e uma família de baselines por regime não é identificável a partir destes dados sem o calendário operacional.

Em carga, a avaliação decorre dentro do domínio amostrado; nas covariáveis, o espaço desloca-se. A sobreposição das densidades de *carga* entre anos consecutivos (índice de *overlap* de núcleos, 0 a 1) situa-se entre 0,79 e 0,83 nos cinco pares completos, com 0,79 no par diagnóstico 2025→2026: as falhas de estabilidade e de calibração das Secções 6.4 e 6.5 ocorrem, no que a *Q* respeita, no interior do domínio amostrado, e não podem ser desculpadas como extrapolação para cargas nunca vistas. O mesmo não vale para as covariáveis: o *overlap* da pressão de *flash* cai a 0,46–0,47 em dois pares e o da temperatura a 0,25 no par diagnóstico de 2026, com a mediana deslocada — as distribuições operacionais mudam sem sair do intervalo observado. Estas medidas são marginais e não estabelecem nem excluem extrapolação *conjunta*; a deslocação das covariáveis é, porém, uma das explicações concorrentes para a má transportabilidade dos modelos aumentados (Secção 6.7).

Os vetores não falham de forma independente. As correlações cruzadas dos resíduos padronizados entre vetores são aproximadamente nulas em todos os pares exceto um: vapor de 24 bar contra vapor de 10 bar, com $r = -0,58$ agregado nos anos completos, entre $-0,36$ e $-0,82$ consoante o ano, e $-0,93$ no parcial de 2026 — uma anti-correlação forte e persistente, compatível com o despacho entre níveis de pressão da rede de vapor: o que um nível consome a mais, o outro tende a consumir a menos — uma hipótese compatível com os dados, não um mecanismo identificado; medição ou reconciliação comum e condições

operacionais omitidas são explicações alternativas em aberto. Registam-se ainda 67 dias com desvios simultâneos $|z| > 2$ em dois ou mais vetores nos anos completos — quase todos com o par 24/10 bar em sinais opostos — e dez no parcial de 2026, estes numa única sequência civil (25 de março a 3 de abril). A consequência para o desenho de alarmes é directa: alarmes simultâneos em vetores acoplados não são evidência independente, e qualquer agregação de alarmes que os some como se o fossem sobrestima a informação disponível.

Os restantes blocos completam o quadro sem o alterar. As caudas dos resíduos são pesadas em células específicas, não uniformemente: quatro anos-vetor têm excesso de curtose acima de 10 (máximo 15,7, no *fuel gás* de 2024), com intervalos MBB largos — e, em contraponto, o vapor de 3 bar é quase simétrico e mesocúrtico em todos os anos, mostrando que uma distribuição marginal bem-comportada pode coexistir com forte persistência e má transportabilidade. Na influência local, o efeito máximo da remoção de uma semana ISO sobre as predições é moderado (0,27 $\hat{\sigma}$, em 1 284 remoções), mas os declives quase nulos dos vapores têm sinal instável a omissões semanais: retirar a semana de 8–14 de dezembro de 2025 troca o sinal do declive do vapor de 10 bar, e no vapor de 24 bar de 2022 dezanove das 52 omissões semanais trocam o sinal — mais um argumento para interpretar efeitos em cargas de referência, nunca sinais de coeficientes. A verificação de plausibilidade regista 8 declives anuais negativos em 35 células e 10 trocas de sinal entre anos completos consecutivos — difíceis de sustentar como resposta física de consumo à carga e coerentes com a identificação fraca diagnosticada nas Secções 6.3 e 6.4, embora consumo líquido, acoplamento entre vetores ou variáveis omitidas permaneçam explicações possíveis — com as gamas de engenharia formais, que permitiriam arbitrar, declaradas indisponíveis. O diagnóstico de eventos operacionais e a análise pós-arranque ficam não estimáveis pela indisponibilidade do calendário (Secção 6.6).

6.9 Síntese: os modos de falha

Nenhum vetor passa o diagnóstico completo — mas nenhum falha da mesma maneira, e é a diversidade dos modos de falha, mais do que qualquer falha individual, que condena a receita única em produção. A Tabela 6.3 cruza os quatro vetores diários com as quatro dimensões avaliadas; a leitura por linhas identifica cinco modos de falha qualitativamente distintos — distintos, não independentes: a anticorrelação entre os dois níveis de vapor (Secção 6.8) liga dois deles.

Os cinco modos de falha. O *fuel gás* é o único vetor com modelo genuíno — e é precisamente por ter uma relação real que o seu modo de falha é visível: deriva paramétrica (declive –30% em cinco anos) absorvida pela recalibração anual, com bandas que falham nos pares que atravessam a deriva. O *vapor de 24 bar* é o caso insidioso: passa nos testes de estabilidade e de calibração porque não há relação nenhuma a falhar — declives anuais em torno de zero, *skill* nulo, uma média disfarçada de modelo. É saúde aparente por

Tabela 6.3: Síntese do diagnóstico por vetor e dimensão. Poder preditivo: *skill* contra a média do treino (Secção 6.3); estabilidade: igualdade dos declives anuais, BH a 5% (Secção 6.4); calibração: cobertura da banda $\pm 2\hat{\sigma}$ nos cinco pares (Secção 6.5); covariáveis: valor incremental forward (Secção 6.7).

Vetor	Poder preditivo	Estabilidade	Calibração	Covariáveis
Fuel gás	real (0,30–0,40 em 4/5)	rejeitada	falha em 2 pares (0,62; 0,98)	prejudicam (até –32%)
Vapor 24 bar	quase nulo; uma média móvel prevê melhor	não rejeitada	dentro do IC (5/5)	prejudicam (4/5)
Vapor 10 bar	nulo	rejeitada; nível sobe até 2025	falha em 4 pares; colapso YTD (0,06)	úteis (4/5), mas frágeis
Vapor 3 bar	errático (sinal instável)	rejeitada (sobrevive a BY); declive muda de sinal	a pior (0,38–0,997, duas direções)	erráticas (–14% a +42%)

vacuidade, e é o vetor que mais enganaria uma auditoria superficial. O *vapor de 10 bar* tem o nível em movimento: subiu de 2 para 15 t GNE/d à mesma carga entre 2020 e 2025 e inverteu na amostra parcial de 2026, com a banda de 2025 a cobrir 6% dos dias por sobreprevisão — o modelo anual persegue um nível que não para quieto. O *vapor de 3 bar* concentra as falhas mais graves em todas as dimensões — declive a trocar de sinal entre anos, a pior calibração nas duas direções — sem falhar em absolutamente tudo: tem ganhos preditivos pontuais e o maior ganho incremental das covariáveis do estudo (+42%, robusto aos blocos), o retrato de uma identificação fraca sobre uma relação que provavelmente nunca foi aproximadamente linear e estática. A *energia elétrica* falha antes de qualquer estatística: um alarme diário sobre uma alocação mensal uniforme é estruturalmente cego por construção (Secção 6.2).

O mecanismo comum: a recalibração anual mascara aquilo que devia expor. As Secções 6.4 e 6.5 são duas faces do mesmo fenómeno. Cada janeiro, o refit anual reabsorve no par (a, b) a deriva acumulada no ano anterior — e o sistema de alarmes, recalibrado sobre o regime já derivado, volta a tratar como normalidade o que um sistema de monitorização deveria assinalar. A consequência é perversa: quanto mais lento e persistente o desvio — seja degradação, incrustação, desativação de catalisador ou uma alteração operacional que estes dados não distinguem —, mais eficazmente a recalibração o esconde; sobram para os alarmes os desvios rápidos, precisamente os que a dependência residual e a descalibração das bandas tornam pouco fiáveis. O sistema é assim cego por construção aos fenómenos lentos que mais importam e ruidoso nos rápidos que menos importam. Sublinhe-se o estatuto da afirmação: é uma propriedade do desenho, demonstrada pela deriva paramétrica que o refit comprovadamente absorve (Secção 6.4) — o que ficou efetivamente mascarado em cada ano não é mensurável sem o calendário operacional (Secção 6.6).

Sensibilidade: o que sobrevive a mexer nas convenções. Todo o diagnóstico assenta em duas convenções herdadas do método de produção: o limiar de carga e a janela anual civil. Uma grelha de sensibilidade pré-registada reavaliou as 104 conclusões do capítulo — poder preditivo contra os três nulos, estabilidade, calibração e valor incremental — sob seis combinações — limiar a 0,8×, 1,0× e 1,2×, janelas civis e janelas de 12 meses ancoradas a 1 de julho — num total de 624 reavaliações, com a célula de referência a reproduzir exatamente os testes deterministas do capítulo. Ao limiar, o diagnóstico é moderadamente robusto: nas duas células de limiar do esquema civil, 20 das 208 reavaliações mudam de rótulo (9,6%), quase todas perdas de significância em pares fronteiros, a que acresce um re-sorteio na própria célula de referência. As exceções substantivas ficam identificadas: a rejeição de estabilidade do fuel gás não sobrevive ao limiar reduzido; a sobre-cobertura do vapor de 3 bar em 2023→2024 degenera para cobertura total (zero alarmes) em ambas as células de limiar — a mudança de seleção e de ajuste não permite isolar uma causa única; e o valor incremental do vapor de 10 bar (Secção 6.7) assenta em limites inferiores encostados a zero: no par 2024→2025, o rótulo muda com a seed da reavaliação (limite +0,007 contra -0,003, com a mesma estimativa) e com o limiar reduzido — é a conclusão mais frágil do capítulo, e fica qualificada como tal.

A janela é outra história: substituir as janelas civis por janelas julho-junho muda 133 das 312 reavaliações (43%). A comparação não isola a âncora: além de mover a fronteira dos anos, o esquema julho-junho retira o primeiro semestre de 2020 e acrescenta o primeiro de 2026 — muda a partição e a cobertura temporal. O caso mais informativo é a própria estabilidade: com janelas julho-junho, o vapor de 24 bar — igualdade não rejeitada em janelas civis — passa a rejeitá-la nas três células, e o vapor de 10 bar deixa de a rejeitar; no mesmo esquema, o valor incremental do 10 bar inverte para perdas confirmadas — estimado, note-se, noutra população e noutro período. A conclusão suportada é que o veredicto sobre uma baseline anual depende de forma mensurável da partição temporal escolhida — onde começa a janela e que meses cobre — e não apenas da física do processo. Para um método que a ISO 50006 trata como neutro, é um resultado central: a escolha da janela é uma decisão de modelação com consequências, e as guidelines do Capítulo 7 tratam-na como tal.

Resposta à questão de investigação. As baselines em produção na unidade não são válidas, de forma uniforme, para os fins que a ISO 50006 lhes atribui: a adequação depende do vetor, do par de anos, do comparador e do objetivo — e nenhum vetor passa o diagnóstico completo. Os cinco modos de falha são distintos, mas partilham uma raiz de desenho: um modelo linear estático, reestimado anualmente sobre janelas convencionais, aplicado a um processo contínuo não-estacionário cujo comportamento os dados — agora replicados e auditáveis, dentro das limitações de proveniência declaradas — documentam em detalhe. O Capítulo 7 converte cada modo de falha numa prescrição; o que este capítulo estabelece é que nenhuma prescrição pode assumir o que estas baselines assumiram.

DISCUSSÃO E PROPOSTA METODOLÓGICA

O Capítulo 6 estabeleceu que o método de *baselines* em produção se reproduz exatamente e não é adequado, de forma uniforme, aos fins que a ISO 50006 lhe atribui. Este capítulo faz três coisas com esse resultado. Primeiro, lê-o em conjunto: o que os cinco modos de falha têm em comum, o que a norma exige e não exige, e porque é que a pergunta certa sobre uma *baseline* de eficiência não é “prevê bem?” mas “revela o desvio que existe para revelar?”. Segundo, converte o diagnóstico numa proposta — um conjunto de linhas orientadoras para construir, aceitar e manter *baselines* em processo contínuo — e demonstra-a na própria unidade: que candidatos da classe linear estática, robustificada e com bandas honestas, passam um critério de aceitação declarado antes de qualquer resultado; e o que se aprende quando, em vez de reajustar o modelo todos os anos, se congela uma referência e se mede tudo o resto como desvio face a ela, incluindo com verdade conhecida por simulação. Terceiro, devolve a proposta ao instrumento do Capítulo 5 como especificação de um bloco de saúde das *baselines*, e declara os limites de tudo o que aqui se afirma. A matemática de cada instrumento consta do Anexo G.

7.1 Leitura integrada do diagnóstico

Reproduzir não é validar. O primeiro resultado do Capítulo 6 — a replicação exata das trinta células vetor-ano — é a condição de tudo o resto, mas não diz nada sobre a adequação do modelo: diz que o que se critica é o que está em produção. Tudo o que se seguiu mostra que um método pode ser reproduzível, documentado e aplicado com disciplina há seis anos, e ainda assim não cumprir nenhuma das três funções que lhe são pedidas — normalizar o consumo pela carga (a carga só tem conteúdo preditivo no fuel gás), sustentar comparações entre períodos (a relação anual não é invariante e o veredicto depende de onde começa o ano) e alimentar alarmes (a banda cobre entre 38% e 99,7% dos dias consoante o vetor e o par de anos).

Cinco modos de falha, uma raiz. Cada vetor falha à sua maneira — o fuel gás por deriva paramétrica que a recalibração absorve; o vapor de 24 bar por vacuidade, uma média disfarçada de modelo; o de 10 bar por um nível em movimento; o de 3 bar por identificação

fraca de uma relação que provavelmente nunca foi linear nem estática; a energia elétrica por não ser uma medição diária. A diversidade importa porque condena a receita única: um remédio para a deriva do fuel gás não serve ao 24 bar, onde não há relação a estabilizar. Mas os cinco partilham uma raiz de desenho, e é sobre ela que a proposta deste capítulo se constrói: um modelo linear estático, reestimado anualmente sobre janelas convencionais, aplicado a um processo cujo comportamento muda mais devagar do que um ano e mais depressa do que a recalibração o assinala. O mecanismo é o da Secção 6.9: cada janeiro, o reajuste reabsorve nos parâmetros o desvio acumulado no ano anterior, e o sistema de alarmes, recalibrado sobre o regime já desviado, volta a tratar como normal o que devia assinalar.

Previsão e deteção são perguntas diferentes. O diagnóstico mediu sobretudo previsão — *skill* face a referências triviais, erro fora da amostra, cobertura de bandas — porque é o que se pode medir sem calendário operacional. Mas a função de uma *baseline* de eficiência não é prever o consumo de amanhã: é servir de referência estável contra a qual um desvio se torna visível. As duas exigências entram em tensão, e a Secção 6.3 já a expôs: uma média móvel de trinta dias prevê o consumo de vapor melhor do que a relação anual com a carga precisamente porque incorpora o passado recente — e, ao incorporá-lo, incorpora também qualquer desvio persistente, tratando-o como o novo normal. Um modelo que segue o processo é um bom preditor e um mau detetor; uma referência congelada é um mau preditor e a única coisa que mede o desvio. O que este capítulo propõe não é escolher entre os dois: é reconhecer que são dois objetos com funções distintas, e que o método em produção tenta ser ambos com um só modelo reajustado uma vez por ano — tarde de mais para prever, cedo de mais para detetar.

Três formas de avaliar, três estimandos. O que se segue avalia *baselines* de três maneiras que respondem a perguntas diferentes, e que convém distinguir antes de ler qualquer número. A primeira, herdada do Capítulo 6, reajusta o modelo em cada ano e aplica-o ao seguinte: mede a transportabilidade da relação anual. A segunda, usada na demonstração das linhas orientadoras (Secção 7.4), mantém esses mesmos cinco pares anuais mas substitui o estimador, a banda ou ambos, e adjudica cada candidato por um critério declarado a priori: mede se existe um candidato aceitável dentro de uma classe. A terceira (Secção 7.5) congela uma referência em 2020 e aplica-a a 2021–2025 sem lhe tocar: mede o desvio face a um ponto fixo, e o que cada componente de um sistema de monitorização — normalizador, escala, monitor, banda — faz a esse desvio. Os três estimandos são diferentes por construção, e o mesmo vetor pode ter leituras que só parecem contraditórias: o vapor de 24 bar é “estável e calibrado” na primeira (declives iguais, banda de produção compatível em cinco pares) e, na terceira, “desloca-se de nível sem que nenhum normalizador acrescente nada à média de 2020”. Não há contradição: a primeira pergunta pela relação com a carga ano a ano, a terceira pelo nível face a um ano fixo. A Tabela 7.1 fixa os três antes de qualquer resultado.

Tabela 7.1: As três formas de avaliar uma *baseline* usadas na dissertação, o que cada uma mede e o que não pode estabelecer.

Avaliação	Desenho	O que mede	O que não estabelece
Diagnóstico (Cap. 6)	modelo do ano y aplicado a $y+1$, cinco pares 2020–2025	transportabilidade da relação anual; calibração da banda; valor de covariáveis	utilidade para detecção; causa da instabilidade
Demonstração (Secção 7.4)	os mesmos cinco pares; estimador, banda e critério de aceitação declarados a priori	se algum candidato da classe passa o critério	impossibilidade da classe; necessidade de modelos com estado
Referência congelada (Secção 7.5)	referência de 2020 aplicada a 2021–2025; simulação com verdade conhecida	desvio face a um ponto fixo; o que cada componente faz ao desvio	poupança, alarme validado, mecanismo; fatos sobre a refinaria a partir da simulação

7.2 Implicações para a conformidade normativa

A ISO 50001 [40] obriga a monitorizar, medir e analisar o desempenho energético; a ISO 50006 [26] operacionaliza-o em indicadores e *baselines*, com variáveis relevantes, fatores estáticos e normalização; a ISO 50015 e o IPMVP [28, 25] tratam da medição e verificação de poupanças. Como o Capítulo 2 mostrou, as três dizem *o que* deve existir e são quase omissas sobre *como validar* o que existe — e carregam o pressuposto tácito de que a relação entre consumo e variáveis relevantes é estável no período de referência e transportável para o de reporte. O Capítulo 6 é, em rigor, um teste desse pressuposto num processo contínuo, e o resultado é que ele não se verifica em nenhum dos cinco vetores da unidade.

A consequência normativa é incômoda mas precisa. Um sistema de gestão de energia pode ser formalmente conforme — *baselines* definidas, variáveis relevantes identificadas, indicadores calculados, revisões anuais documentadas — e assentar em modelos que não prevêm melhor do que uma média, cujos parâmetros mudam de sinal entre anos e cujas bandas de alarme oscilam entre o silêncio e o ruído. A conformidade certifica a existência do instrumento, não a sua validade; e a norma, ao não exigir validação, não protege a organização dessa diferença. A ISO 50006 admite explicitamente a recalibração da *baseline* quando as condições mudam — e é precisamente essa admissão que, aplicada como rotina anual, produz o mecanismo da Secção 7.1: a recalibração sancionada pela norma é o que esconde o desvio que a norma quer ver.

Daqui decorre a posição desta dissertação: os requisitos de validação têm de ser acrescentados pela organização, porque a norma não os traz. O protocolo de avaliação do Capítulo 4 e as linhas orientadoras que se seguem são uma proposta concreta desses requisitos — compatível com o enquadramento normativo, porque não pede nada que a norma proíba, e mais exigente do que ele, porque pede que uma *baseline* prove antes de ser usada aquilo que a norma assume.

7.3 Linhas orientadoras para a construção e aceitação de *baselines*

As linhas orientadoras foram formuladas antes da demonstração, revistas em quatro rondas de revisão adversarial independente (Anexo F) e fixadas na versão que aqui se descreve. Cada uma responde a um modo de falha do Capítulo 6 ou a um defeito apontado na revisão; nenhuma foi ajustada depois de conhecidos os resultados da Secção 7.4. Apresentam-se por ordem de aplicação.

Dados reconciliados como pré-condição. Nenhuma *baseline* se estima sobre dados que não passaram a validação de fontes do Capítulo 5: imputações sinalizadas e contadas, proveniência com *hashes*, e um perfil dos dados — cobertura, mecanismo de falta, efeito de qualquer filtro de seleção — lido e aceite por uma pessoa antes de qualquer análise. O erro de seleção que invalidou a análise preliminar desta dissertação (um limiar de carga escrito à mão em vez de lido da configuração oficial) é o exemplo do que este passo existe para apanhar.

Domínio definido nas variáveis explicativas, nunca no consumo. A *baseline* declara o intervalo de carga em que foi estimada, justificado por percentis de operação ou limites físicos, e um critério de regime estacionário (variação de carga abaixo de um limiar; exclusão das primeiras 48 a 72 horas após arranque). A seleção faz-se sobre os regressores pré-especificados, nunca sobre o consumo — selecionar sobre a variável resposta trunca a distribuição do erro e enviesada o modelo [20]. O que a Secção 6.2 mostrou — o limiar oficial remove outro regime operativo, não uma cauda — torna esta declaração obrigatória: o domínio de validade existe de qualquer forma; a diferença está em declará-lo ou descobri-lo. Na aplicação, um dia fora do domínio é sinalizado como tal e o seu alarme é suprimido: não é uma anomalia, é uma pergunta a que o modelo não sabe responder.

Exclusões por causa, nunca por valor. Um dia é excluído do treino por um código de razão pré-registado e ligado ao registo de operações (paragem, arranque, intervenção, campanha), com a declaração de que usos essa exclusão afeta — treino, avaliação de desempenho e avaliação de alarmes são decisões distintas. Nunca por ser um valor extremo. Fica declarado o risco residual: um registo operacional pode ele próprio ter sido motivado por um comportamento energético anómalo, e “documentado” não é sinónimo de “exógeno”.

Especificação antes de robustificação. Entre o modelo univariado na carga e qualquer modelo não linear existe o degrau que a ISO 50006 e o IPMVP sancionam [26, 25]: a regressão linear múltipla com variáveis relevantes pré-especificadas (densidade da carga, condições de *flash*, sinais de modo de operação). A Secção 6.7 mostrou o que este degrau vale na unidade — consistente num vetor, prejudicial noutros — e daí a regra: uma covariável é admitida só por valor preditivo incremental demonstrado fora da amostra,

para a frente no tempo, com um critério que inclua a banda e não apenas o erro pontual; nunca por catálogo.

Estimação robusta, pré-especificada. O estimador primário é declarado antes de ver os dados — um estimador-M de Huber [22, 23] com constante de afinação fixa ($c = 1,345$ [21]) e escala pela mediana dos desvios absolutos — com os mínimos quadrados reportados ao lado, e um limiar de divergência declarado entre os dois que, se excedido, obriga a investigar: a divergência pode significar má especificação, não valores atípicos. A alavancagem trata-se separadamente, porque um estimador de Huber não resiste a pontos de alavancagem elevada [44]. O estimador de Theil-Sen [48] serve de referência livre de distribuição em regressão simples. Um ponto e uma banda robustos são problemas diferentes, e a linha seguinte trata do segundo.

Bandas honestas, com três desfechos possíveis. A banda de alarme constante $\pm 2\hat{\sigma}$ assume resíduos independentes e homocedásticos que a Secção 6.8 mostrou não existirem. A rota primária modela explicitamente a dependência residual — um processo autorregressivo sobre os resíduos [7], com desfasamentos civis exatos e ordem escolhida só no treino — e produz intervalos condicionais, a um passo, validados pela cobertura empírica no ano seguinte. A rota de sensibilidade é a regressão quantílica [30], com restrições de não cruzamento [8] e incerteza por *bootstrap* de blocos — sobre uma janela plurianual, nunca sobre um ano ($n \approx 300$ dias a $\tau = 0,025$ deixa cerca de sete observações em cada cauda). O ponto essencial é o terceiro desfecho: a avaliação pode concluir que *nenhuma* rota é suportada para um vetor, e esse veredicto é reportável e bloqueia o alarme por banda nesse vetor. Uma banda não validada não é uma banda pior; é a ausência de banda.

Critério de aceitação com validação temporal encadeada. Um candidato — estimador, banda e domínio — só entra em produção depois de passar um critério declarado antes de qualquer resultado, avaliado para a frente no tempo. A formulação original exigia uma partição selada: construção e afinação em 2020–2023, seleção congelada em 2024, uma única avaliação em 2025 intocado. Foi substituída, por decisão datada, por validação temporal encadeada — os mesmos cinco pares anuais do diagnóstico —, porque 2025 e o parcial de 2026 já tinham informado o Capítulo 6 e nenhum resultado obtido depois disso pode chamar-se *holdout*. O critério tem dois membros e aceita um candidato apenas se ambos se cumprem: conteúdo preditivo — ganho sobre a média do ano de treino, com o intervalo de confiança a excluir zero, em pelo menos quatro dos cinco pares (é o que impede que um modelo vazio, com $R^2 \approx 0$, seja aceite por ter uma banda razoável, o defeito da primeira versão das linhas orientadoras); e banda suportada — cobertura compatível com a nominal, pelo intervalo, em pelo menos quatro dos cinco pares. O limiar de quatro em cinco foi fixado antes de qualquer resultado e não se mexe depois; a Secção 7.4 mostra o que depende dele.

Recalibração por evidência, com políticas separadas. Gerar um alarme, investigar, suspender temporariamente um modelo, recalibrar e verificar a recalibração são cinco decisões com políticas distintas e declaradas. A recalibração exige uma mudança detetada — um sinal de um monitor sequencial [41, 33] sobre as inovações, não uma data no calendário — mais uma revisão documentada; mas a revisão pode concluir “causa desconhecida, recalibrar com sinalização”, porque exigir causa demonstrada incondicionalmente atrasaria a adaptação exatamente quando o sistema muda. Os mesmos resíduos nunca servem para declarar a mudança e para certificar o modelo recalibrado: a certificação usa só dados posteriores. É esta linha que substitui a recalibração anual de rotina, e é a resposta direta ao mecanismo da Secção 7.1.

Mínimos de dados e governança. Não se estima uma *baseline* se o número de observações está abaixo de um mínimo declarado (formalizando o parâmetro que o método de produção já tem), se o treino cobre menos do que uma fração declarada do domínio de aplicação, ou se a fração imputada excede um teto. A governança — versões, registo de alterações, aprovação nominal, revisão agendada — e uma ficha de uma página por *baseline* (domínio, janela, exclusões com códigos de razão, estimador, método de banda e o seu desfecho, resultados da aceitação, *hash* de proveniência) fecham o conjunto. A ISO 50001 é uma norma de sistema de gestão; sem governança, as linhas orientadoras não são adotáveis.

7.4 Demonstração na unidade

As linhas orientadoras foram demonstradas nos quatro vetores diários da unidade, sobre os mesmos cinco pares anuais 2020→2021 a 2024→2025 do Capítulo 6, com constantes fixadas a priori ou afinadas apenas dentro do ano de treino, conclusões só por exclusão do intervalo de confiança por *bootstrap* de blocos móveis, e margens materiais declaradas como não elicitadas — não há, nesta unidade, um limiar acordado a partir do qual um desvio importa. Nenhuma linha desta secção se descreve como *holdout*.

7.4.1 Estimadores robustos

Para cada vetor e par anual estimaram-se três retas sobre o ano de treino — mínimos quadrados (o método de produção), Huber e Theil–Sen — e compararam-se as perdas absolutas diárias no ano seguinte, sem reestimação, por contraste emparelhado $|e_{OLS}| - |e_{rob}|$ com intervalo de confiança a 95%. São quarenta contrastes.

Nenhum estimador domina (Tabela 7.2). O Huber ganha em onze dos vinte contrastes e perde em seis; o Theil–Sen é mais extremo, sete contra oito. O maior ganho é do Theil–Sen no vapor de 3 bar em 2022→2023 (+4,68 t GNE/d, +15,3%). Três leituras qualificam a contagem. Contar vitórias não é agregar: no vapor de 24 bar o Huber ganha três pares em cinco e tem, ainda assim, o erro absoluto médio agregado ligeiramente pior. A explicação intuitiva — “a robustez ajuda onde há caudas pesadas” — é contradita pelos próprios dados: o vapor de 3 bar, onde o Huber mais ganha, é o vetor com menor curtose residual, e

Tabela 7.2: Contrastes emparelhados de perda absoluta no ano seguinte, quatro vetores $\times$ cinco pares. “Robusto melhor” e “OLS melhor”: o intervalo MBB a 95% exclui zero do lado respetivo.

Estimador	Robusto melhor	OLS melhor	Sem evidência
Huber ($c = 1,345$)	11	6	3
Theil-Sen	7	8	5

o fuel gás de 2024, com curtose 15,7, não beneficia. E melhor ponto não é melhor banda: no vapor de 24 bar em 2024 $\rightarrow$ 2025 o Huber reduz o erro médio em 2,9% e a banda marginal construída sobre a sua escala robusta cobre 48,5% dos dias, contra 93,9% da banda de produção — a escala robusta é 0,55 da escala dos mínimos quadrados, e uma banda mais estreita em torno de um ponto marginalmente melhor é uma banda muito pior: a nitidez só vale sujeita à calibração [15]. A robustez na estimação e a robustez do detetor são problemas distintos, e esta é a razão de a linha orientadora os separar.

7.4.2 Bandas honestas

A rota primária ajustou, sobre os resíduos dos mínimos quadrados de cada ano de treino, um processo autorregressivo com desfasamentos civis exatos e ordem escolhida pelo critério de informação bayesiano [47] só no treino (entre um e sete dias), com predição a um passo no ano seguinte e recurso declarado à banda marginal quando o histórico não chega; produziu duas construções, uma gaussiana ($\pm 2\hat{\sigma}$ das inovações, primária no veredicto) e uma por quantis empíricos das inovações. A rota de sensibilidade foi a regressão quantílica a $\tau = 0,02275$ e $0,97725$ — os quantis que correspondem a $\pm 2\sigma$ numa normal — com verificação de não cruzamento que recusa o resultado em vez de o corrigir. Uma banda é suportada num vetor se o intervalo de confiança da sua cobertura inclui 95,45% em pelo menos quatro dos cinco pares, sem degeneração.

Tabela 7.3: Cobertura no ano seguinte das quatro construções de banda, vinte pares vetor-transição. “Inclui”: o intervalo MBB da cobertura inclui a referência de 95,45%; “sub” e “sobre”: exclui-a por baixo ou por cima; NE: não estimável (não convergência declarada). Meia-largura mediana relativa à banda de produção.

Banda	Inclui	Sub	Sobre	NE	Meia-largura
Produção $\pm 2\hat{\sigma}$	10	7	3	0	1,00
AR, gaussiana	9	6	5	0	0,63
AR, quantis empíricos	10	6	4	0	0,59
Quantílica anual	5	12	2	1	0,97

O veredicto é que **nenhuma rota candidata é suportada em nenhum dos quatro vetores** (Tabela 7.3) — e é preciso dizê-lo com exatidão, porque a frase “nenhuma banda é suportada” seria falsa: a banda de produção do vapor de 24 bar é compatível com a referência nos cinco pares. O que a rota autorregressiva faz é instrutivo nas duas direções.

Recupera as falhas mais graves da produção — no vapor de 10 bar em 2024→2025 a cobertura passa de 52,9% para 95,6% (mais 42,7 pontos, intervalo [30,2; 56,3]); no de 3 bar em 2021→2022, de 37,8% para 76,1% — e quebra três dos cinco sucessos do 24 bar, porque a sua banda, 0,63 da largura da produção, é estreita de mais onde a de produção já era adequada. O saldo nos vinte pares é de menos um. Dois pormenores mudam a leitura. A rota autorregressiva não é só uma banda: ao usar os resíduos dos dias anteriores, muda o *centro* da predição — é um modelo diferente, com memória, e parte do que recupera é o nível que os mínimos quadrados anuais não seguem (o que a Secção 7.5 retoma). E a regressão quantílica sobre um ano tem sete ou oito observações por cauda: o seu resultado negativo é da implementação anual, que a linha orientadora já desaconselhava, e não da rota.

7.4.3 O critério de aceitação e o que decidiu

O critério foi aplicado por adjudicação pura sobre os resultados já publicados — o poder preditivo do Capítulo 6 e as bandas da secção anterior —, sem recalculá-los nada, com cada valor lido de uma corrida identificada e verificada por *hash*. Um candidato é um par (estimador, banda); com os mínimos quadrados e as quatro construções de banda, são dezasseis decisões.

Tabela 7.4: Adjudicação dos dezasseis candidatos com estimador de mínimos quadrados. Conteúdo preditivo: pares (em cinco) com ganho sobre a média do treino e intervalo a excluir zero; banda: pares com cobertura compatível com a nominal. Aceite se ambos $\geq 4/5$.

Vetor	Cont. preditivo	Produção	AR gauss.	AR emp.	Quantílica	Aceites
Fuel gás	4/5	3/5	3/5	3/5	2/5 + NE	0/4
Vapor 24 bar	1/5	5/5	2/5	2/5	2/5	0/4
Vapor 10 bar	0/5	1/5	3/5	3/5	0/5	0/4
Vapor 3 bar	2/5	1/5	1/5	2/5	1/5	0/4

Nenhum dos dezasseis candidatos é aceite (Tabela 7.4), e as razões separam-se limpamente por vetor. O fuel gás cai só pela banda: tem conteúdo preditivo em quatro dos cinco pares, mas nenhuma construção o acompanha com cobertura compatível em mais de três. Os vapores caem pelo conteúdo preditivo — um, zero e dois pares em cinco — e a única célula em que uma banda passa, a de produção do 24 bar, protege um modelo sem relação a proteger: é o espelho do fuel gás, uma banda suportada sem modelo por trás.

Os candidatos robustos completos — Huber e Theil–Sen, cada um com a banda marginal sobre a sua escala robusta e com a rota autorregressiva sobre os seus resíduos, mais dezasseis decisões — não mudam o desfecho: zero aceites. Os quatro candidatos do fuel gás mantêm o conteúdo preditivo (quatro em cinco com ambos os estimadores) e nenhuma banda passa de três em cinco; os vapores continuam sem conteúdo preditivo (o melhor, Theil–Sen no 3 bar, chega a três em cinco). Trocar o estimador pontual não resgata a classe. A correção autorregressiva sobe o número de pares compatíveis de nove, com a

banda marginal, para dezoito — sem nunca chegar a quatro num mesmo candidato; o caso extremo é o vapor de 24 bar com Theil–Sen em 2024→2025, em que a banda marginal cobre 14,6% e a autorregressiva 96,6%.

O que o zero em trinta e dois significa, e o que não significa, tem de ficar escrito com o mesmo cuidado. Significa que nenhuma das combinações avaliadas — três estimadores, seis construções de banda, quatro vetores — cumpre o critério declarado sob a regra de quatro em cinco. Não demonstra a impossibilidade da classe linear, nem a necessidade de modelos com estado — essa frase chegou a constar das fichas e foi retirada. E o resultado é sensível ao limiar: com uma regra de três em cinco seriam três candidatos aceites em dezasseis; a regra de quatro em cinco estava pré-registada e não se altera depois de conhecido o resultado, mas o leitor deve saber que a decisão assenta em cinco pares anuais, e que a potência de uma regra binária sobre cinco observações dependentes nunca foi calculada (Secção 7.7). O que a demonstração estabelece de sólido é o *procedimento*: um critério declarado a priori, adjudicação separada do cálculo, razões de rejeição distintas por vetor, e um resultado negativo que fica publicado como tal em vez de ser ajustado até aparecer um vencedor.

7.4.4 Fichas por *baseline*

A última linha orientadora foi demonstrada produzindo, para cada um dos quatro vetores, a ficha de uma página que a governança exige: domínio de validade, janela, exclusões, estimador, método de banda e o seu desfecho, resultados do critério de aceitação, e proveniência — setenta e seis campos por vetor, cada um lido de uma corrida identificada e verificado por *hash* contra o manifesto de origem, sem nenhum valor escrito à mão. As fichas não calculam nada: consolidam. E é exatamente por isso que servem de especificação para a plataforma (Secção 7.6): o que uma pessoa precisa de saber para confiar numa *baseline* cabe numa página, desde que cada campo tenha origem rastreável. Duas erratas apanhadas em revisão — um máximo de 2026 publicado como se fosse do período 2020–2025, e uma frase sobre “deriva de nível como falha estrutural documentada” que as corridas não sustentam — foram corrigidas na versão final e ficam registadas no Anexo F.

7.5 Referência congelada e verdade conhecida

A demonstração anterior manteve a perspetiva do método de produção: reajustar todos os anos e perguntar se o ajuste transporta. A exploração que se segue muda de perspetiva. Congela uma *referência* — a relação estimada em 2020, com a sua escala de erro e, quando aplicável, o seu estado inicial — e aplica-a a 2021–2025 sem lhe tocar. Tudo o que se mede na aplicação passa a ser desvio face a 2020, e o desenho separa três objetos que o método de produção mistura num só: o resíduo da referência (o desvio físico face ao ponto fixo), o estado filtrado (o que um modelo adaptativo segue) e a inovação (o que o filtro não previu).

O reajuste anual é aqui uma sensibilidade, não o primário. Todos os resumos usam uma população declarada — dias de 2021–2025 retidos pela seleção oficial, dentro do suporte de carga de 2020, com observação e predição finitas — e uma comparação entre modelos faz-se sempre na interseção dessas populações; foi a imposição desta regra, numa revisão independente, que inverteu várias ordenações da primeira versão desta exploração, e a versão que aqui se cita é a corrigida.

7.5.1 O que muda quando não se reajusta

A referência congelada mede o desvio. Aplicada a 2021–2025 na população comum aos cinco normalizadores avaliados ($n = 876$ dias), a relação de 2020 tem, no fuel gás, *skill* de 41 a 54% face à média de 2020 — os normalizadores continuam a bater a média cinco anos depois. No vapor de 24 bar nenhum normalizador acrescenta nada à média de 2020 (de $-5,6\%$ a $+0,3\%$); no de 10 bar o ganho é de 2 a 6%; no de 3 bar a média de 2020 é o melhor “modelo” de todos, por 16 a 25%. O desvio padronizado médio face à referência é de $0,97\sigma$ no fuel gás e $1,73\sigma$ no vapor de 10 bar: a aplicação já não se parece com o ano de referência, e um normalizador congelado em 2020 é o que mede essa distância. Uma banda de 95% calibrada em 2020 cobre, em 2021–2025 e nos dias em que a comparação é admissível, entre 0,564 e 0,984 dos dias consoante o vetor, o modelo e a regra — mediana entre vetores de 0,71 a 0,86 por modelo —, com o vapor de 24 bar acima de 0,94 em todos os tercis de carga e o de 10 bar a cair a 0,43 no tercil de carga baixa. Isto é a medição, não um defeito a corrigir: a banda diz que a aplicação já não se parece com a referência, e nenhuma banda é alargada até o número voltar. Perder cobertura nominal face a uma referência congelada não é, por si, um veredicto de ineficiência (Secção 7.7); é a quantidade que um sistema de monitorização deve mostrar e o método de produção reabsorve.

Um controlo adaptativo cobre mais, por seguir o desvio. Nos mesmos dias, um controlo por quantis móveis dos noventa dias civis anteriores — só com passado admissível — cobre 0,87 a 0,91 dos dias nos quatro vetores, contra 0,60 a 0,99 da banda fixa; e fá-lo com uma banda mais estreita, em unidades da escala de 2020, no vapor de 10 bar (3,02 contra 4,48) e no de 24 bar, e mais larga no fuel gás. Cobre mais porque se adapta ao desvio que a banda fixa existe para revelar — é a Secção 7.1 em números — e por isso não é um substituto: é um controlo, pontuável em 38% dos dias primários (exige sessenta erros admissíveis nos noventa dias anteriores).

Um desvio inserido sobrevive à referência fixa e não sobrevive ao reajuste. Para medir o mecanismo diretamente, inseriu-se um desvio conhecido — um degrau e uma rampa, em unidades da escala de cada vetor — sobre os dados reais de aplicação, e mediu-se a fração desse desvio que sobrevive em cada canal. O resíduo da referência congelada preserva-o por inteiro, em qualquer das três leituras (janela inteira, dias em amplitude plena, primeira quinzena em amplitude plena) — é uma identidade algébrica, não um mérito, e é o que “referência” significa. Um reajuste da referência sobre o período desviado

apaga um degrau por completo e deixa passar 3% de uma rampa. E a inovação de um filtro de nível [12] assimila um desvio sustentado em poucos dias: da primeira quinzena de um degrau retém 0,136; da janela inteira, 0,002; uma rampa nunca chega a produzir inovação, porque sobe mais devagar do que o filtro aprende. Esta última leitura é sobre a inovação de um filtro, não sobre uma estatística de monitorização — se um monitor deteta a mudança é a pergunta da secção seguinte. O que fica estabelecido aqui é o mecanismo do Capítulo 6, agora medido: reajustar é apagar.

Reajustar com janelas curtas segue melhor onde há o que seguir. A sensibilidade que reajusta a referência com janelas móveis de seis, doze e vinte e quatro meses, ou expansiva [43], dá uma leitura qualitativa que não depende dos números finais (em revisão à data desta versão): no vapor de 10 bar — o vetor com o desvio de $1,73\sigma$ — a janela mais curta tem o menor erro e o maior salto de parâmetros entre reajustes, e o erro cresce com o comprimento da janela; no fuel gás a ordem inverte-se, e a janela expansiva tem o menor erro e o menor salto, porque não há desvio que compense o ruído de reajustar com poucos dados. Quem segue melhor é quem salta mais, mas só onde há o que seguir — e um sistema que escolhesse a janela pelo erro escolheria, no 10 bar, exatamente o modelo que mais depressa esconde o desvio.

7.5.2 Monitor e *baseline* com verdade conhecida

A pergunta que o calendário operacional tornou não estimável no Capítulo 6 — que desvio o sistema deteta, e o que importa mais para o detetar — só pode responder-se com verdade conhecida. Construiu-se, para cada vetor, um gerador com a relação de 2020 (mínimos quadrados com as covariáveis de referência), ruído autorregressivo de primeira ordem com $\rho = 0,6$ e dispersão igual à dos resíduos de 2020, 366 dias de treino com a máscara real de dias admissíveis de 2020 e uma aplicação de noventa dias; os limiares de cada monitor foram calibrados sob a hipótese nula a uma taxa de falso sinal de 5% e verificados (quarenta canais entre 0,020 e 0,072, um acima do nominal pelo limite de Wilson [54], compatível com o acaso). Sobre este gerador inseriram-se alternativas conhecidas — degrau e rampa de uma escala, alargamento da dispersão, recuperação, resposta à carga — em quatrocentas réplicas por célula, e mediu-se a taxa de deteção de cada combinação de *baseline* (mínimos quadrados ou modelo aditivo [19, 55]) e monitor (resíduo bruto, filtro de nível, soma acumulada, e canais de carga e de escala). **Nada nesta secção é um facto sobre a refinaria:** é o comportamento de métodos sobre um gerador que escrevemos, e deve ser lido como tal.

O monitor pesa; a *baseline* não — nas oito células declaradas. As oito comparações declaradas como primárias antes da execução (Tabela 7.5) dizem, nos quatro vetores, a mesma coisa: trocar o monitor de nível por uma soma acumulada compra entre um terço e metade da taxa de deteção de um degrau de uma escala, com os quatro intervalos longe de zero; trocar a *baseline* linear por um modelo aditivo custa um a três pontos, e

Tabela 7.5: Diferença de taxa de detecção de um degrau de 1σ , emparelhada por réplica, com intervalo percentil de 2 000 reamostragens. Esquerda: trocar a *baseline* (mínimos quadrados $\rightarrow$ modelo aditivo) com o monitor de nível fixo. Direita: trocar o monitor (filtro de nível $\rightarrow$ soma acumulada) com a *baseline* fixa. Gerador com $\rho = 0,6$.

Vetor	Trocar a <i>baseline</i>	IC 95%	Trocar o monitor	IC 95%
Fuel gás	-0,028	[-0,052; -0,005]	+0,323	[0,273; 0,370]
Vapor 24 bar	-0,013	[-0,040; 0,015]	+0,438	[0,388; 0,487]
Vapor 10 bar	-0,020	[-0,045; 0,003]	+0,490	[0,440; 0,540]
Vapor 3 bar	-0,028	[-0,060; 0,003]	+0,390	[0,343; 0,438]

só no fuel gás o intervalo exclui zero — a favor da linear. Os quatrocentos e quarenta contrastes secundários, publicados sem nunca serem promovidos, dizem onde isto *não* vale: num alargamento puro de dispersão a soma acumulada *perde* (-0,28 em média), porque acumula desvios de média e esses cancelam-se; em rampas e recuperações compra 0,29 e 0,20; e num banco com interação carga $\times$ densidade a *baseline* aditiva ganha. A escolha do monitor é um compromisso, não uma melhoria — e nenhuma recomendação vale sem a natureza do desvio e a autocorrelação medidas ao lado.

A dependência decide quanto se deteta. O gerador primário tem $\rho = 0,6$, que é a autocorrelação residual observada no fuel gás; os três vapores estão entre 0,8 e 0,9, e a subir (Secção 6.8). O lote de sensibilidade responde ao que isso muda. Num degrau de uma escala, a soma acumulada deteta 0,96 das réplicas a $\rho = 0,6$, 0,59 a $\rho = 0,9$ e 0,39 a $\rho = 0,95$ — neste último caso igual ao resíduo bruto (0,35): a vantagem do monitor desaparece. Numa rampa, a taxa cai de 0,64 para 0,27 e 0,17. A leitura para os vapores é, por isso, mais modesta do que a das oito células primárias: na dependência que eles exibem, um degrau de uma escala é detetado dentro do horizonte em cerca de metade das réplicas pelo melhor monitor, e uma rampa em um quarto. O monitor continua a pesar; a detetabilidade absoluta é pobre, e o resultado do fuel gás não transfere.

O desvio mínimo detetável, no gerador. Sobre a curva de detecção por amplitude de degrau, o desvio a que a soma acumulada deteta metade das vezes situa-se entre $0,51\sigma$ (vapor de 3 bar) e $0,63\sigma$ (vapor de 10 bar), contra 0,87 a $1,10\sigma$ do filtro de nível e $0,95$ a $1,15\sigma$ do resíduo bruto. Em percentagem do consumo médio dos dias retidos de 2020, o desvio mínimo detetável da soma acumulada é 4,5% no fuel gás, 9,4% no vapor de 3 bar e 14,7% no de 24 bar; o vapor de 10 bar é um fluxo líquido com sinal e não admite percentagem. Trinta e duas das oitenta curvas estão censuradas à direita — todas nos canais de carga e de escala, que não existem para ver um degrau de nível — e são publicadas como limite aberto, nunca como número. Estes valores são propriedades do gerador a $\rho = 0,6$; na refinaria, e nos vapores, o parágrafo anterior diz o que se pode esperar.

Três sinais falsos, demonstrados. O mesmo aparelho serviu para demonstrar, com verdade conhecida, três leituras sedutoras que a prática de monitorização produz. Primeira: duas séries *independentes* têm R^2 diário de 0,0025, mensal de 0,18 e acumulado de 0,9999 — a correlação de séries acumuladas é inteiramente fabricada pela acumulação [56, 16], e um gráfico de consumo acumulado contra carga acumulada não é evidência de relação nenhuma. Segunda: branquear a série antes de monitorizar — usar as inovações de um modelo autorregressivo como estatística — remove exatamente a mudança de nível que se quer ver [1, 53]: num degrau de uma escala, a inovação autorregressiva sinaliza à sua taxa nula (0,095), enquanto uma média móvel de trinta dias deteta 0,895. Terceira: a leitura de que a anticorrelação entre os vapores de 24 e 10 bar (Secção 6.8) “impede a coocorrência” de alarmes — que constou de uma versão anterior desta exploração e foi retirada — assentava em pontuar o vapor de 10 bar como unilateral; na lateralidade declarada, com os quatro vetores desviados, um canal conjunto sinaliza em 0,068 das réplicas contra 0,570 da melhor margem individual, e com um só vetor desviado em 0,022. Uma contagem conjunta exige mais do que a melhor margem e por isso deteta menos; não é a correlação que o impede.

O que a exploração com referência congelada ainda não fecha. Esta exploração foi submetida a duas revisões independentes. A primeira aprovou a integridade da cadeia de resultados e reprovou a conformidade científica de sete pontos, todos corrigidos e republicados. A segunda, sobre a versão republicada, identificou que várias das suas partes — a comparação entre esquemas de referência, a ordenação de janelas de reajuste, a inserção de desvios sobre estados publicados, a agregação a frequências semanal e mensal e o suporte da eletricidade — ainda não estimam exatamente a comparação declarada (comparam populações diferentes, comprimem o calendário, ou incluem extrapolações no resultado primário). As correções estão em curso à data desta versão; este capítulo cita, com números, apenas os lotes que essa revisão classificou como aceitáveis, e onde uma parte em revisão entra, entra qualitativamente e assinalada.

7.6 Implicações para a plataforma

O Capítulo 5 entregou um instrumento que torna o diagnóstico possível; este capítulo devolve-lhe uma especificação. O que se segue é o bloco de saúde das *baselines* — o que o *dashboard* tem de mostrar para que uma *baseline* seja usada com conhecimento do seu estado — formulado como requisitos, cada um ancorado num resultado desta dissertação.

Duas pistas, não uma. O método de produção usa um só modelo para normalizar e para alarmar. A plataforma deve manter duas pistas visíveis lado a lado: o modelo anual em vigor, para reporte normalizado e comparação entre períodos, como a ISO 50006 pede; e uma referência congelada, com o desvio padronizado face a ela e um monitor sequencial sobre esse desvio, para deteção. A Secção 7.5.1 mostrou que só a segunda mede o desvio;

a Secção 7.5.2 mostrou que o monitor sobre ela é o que mais pesa na detecção. A data e a razão de cada mudança de referência são registadas.

Domínio visível, alarme suprimido fora dele. Cada *baseline* publica o intervalo de carga e as condições em que foi estimada; um dia fora desse domínio é mostrado como “fora de domínio”, não como anomalia, e o seu alarme é suprimido. O limiar de carga oficial já define um domínio implícito (Secção 6.2); a plataforma torna-o explícito.

Calibração monitorizada, não assumida. A cobertura efetiva da banda de alarme nos últimos noventa e cento e oitenta dias, com intervalo de confiança que respeite a dependência, é um indicador do bloco de saúde — não a taxa de alarmes, que confunde descalibração com desvio. Uma cobertura que exclui a nominal pelo intervalo desencadeia a política de investigação, não uma recalibração automática.

Ficha por *baseline*. Os setenta e seis campos da Secção 7.4.4 — domínio, janela, exclusões com códigos de razão, estimador, método de banda e desfecho, resultados do critério de aceitação, proveniência — são a ficha que acompanha cada *baseline* na plataforma, gerada dos resultados e nunca editada à mão. Uma *baseline* sem ficha não está em produção.

Políticas separadas e registadas. Alarme, investigação, suspensão, recalibração e verificação pós-recalibração são cinco estados com transições declaradas; a recalibração exige sinal do monitor mais revisão documentada, com a opção “causa desconhecida, recalibrar com sinalização”; a certificação do modelo recalibrado usa só dados posteriores. O registo de versões, aprovações e revisões é parte do bloco, não um documento à parte.

O que a plataforma não pode fazer sem informação que não tem. Nenhum dos requisitos acima classifica um desvio como ineficiência, nem um alarme como falso. Isso exige o calendário operacional, rótulos de eventos e margens materiais elicitadas com a operação — as três coisas que esta dissertação não teve. A plataforma pode e deve registar o desvio e o alarme com a sua proveniência; a classificação é uma decisão humana até que essa informação exista, e o desenho deve deixar espaço para a receber.

7.7 Limitações

Do estudo. Uma unidade, seis anos completos, um único *snapshot* de dados já explorados: não há afirmação fora de amostra que sobreviva, e o desenho não a tenta — a demonstração das linhas orientadoras é retrospectiva e encadeada, nunca *holdout*, porque 2025 e o parcial de 2026 já tinham informado o diagnóstico. As conclusões são condicionais ao modelo linear, à seleção oficial e às janelas anuais que o método de produção herdou. O calendário operacional, os rótulos de eventos e as margens materiais não estavam disponíveis: nenhum desvio é ineficiência, nenhuma excursão é falso alarme, nenhuma cobertura é qualidade

de detecção, e a detetabilidade só foi estudada em simulação. Há erro de medição na carga, possível endogeneidade (a operação reage aos alarmes), agregação diária que esconde dinâmica intra-diária, um mecanismo de falta não identificável sem fonte operacional, e nenhum padrão de referência independente do modelo Power BI original para as observações selecionadas. A energia elétrica é uma alocação mensal e fica fora de qualquer inferência diária.

Da inferência. Todos os veredictos assentam em cinco pares anuais e em regras binárias sobre eles; a potência dessas regras sob a dependência observada não foi calculada, e o zero em trinta e dois passa a três em trinta e dois com uma regra de três em cinco. O intervalo de confiança por *bootstrap* de blocos usa um bloco base de sete dias sobre resíduos com autocorrelação até 0,90; a sua cobertura nominal não está demonstrada — a validação por simulação a $\rho = 0,90$ deu 0,8925 (intervalo de Wilson 0,86 a 0,92), o que não é evidência de cobertura inferior a 0,90 nem prova de cobertura de 0,95. Um contraste que exclui zero por pouco está dentro do erro de calibração do próprio instrumento, e a sensibilidade ao comprimento de bloco reportada nas Secções 6.4 e 6.5 é o sintoma visível disso. A correção de multiplicidade aplica-se só à família dos testes de estabilidade; todos os outros resultados são por contraste, e a sua contagem não é evidência conjunta. “Não rejeitado” nunca é “equivalente” [34]: não há margens práticas elicítadas.

Da simulação. O gerador primário tem $\rho = 0,6$, o regime do fuel gás, não o dos vapores; depende da relação de referência, das máscaras, do ruído e do orçamento de réplicas escolhidos; o modelo aditivo corre com hiperparâmetros fixos; o desvio mínimo detetável é do gerador, não da unidade; e um número obtido em quatrocentas réplicas de um gerador que escrevemos não é um facto sobre a refinaria, por muitas réplicas que tenha.

Das linhas orientadoras. A classe linear robustificada, com bandas honestas e critério de aceitação, leva o modelo estático ao máximo defensável — e não resolve a não-estacionariedade estrutural que o diagnóstico documenta. O critério de aceitação é um procedimento com critérios declarados, demonstrado com $n = 5$; o que ele decide depende do limiar, e o que não decide é a impossibilidade da classe. A resposta completa — modelos com estado de degradação, referência congelada com monitor sequencial em produção, validação com eventos reais — é a investigação seguinte (Capítulo 8), para a qual ficam prontos a plataforma, o diagnóstico, o critério de aceitação e a evidência auditável que os sustenta.

CONCLUSÕES E TRABALHO FUTURO

8.1 Conclusões

8.2 Roteiro de modelos sucessores

8.3 Trabalho futuro

BIBLIOGRAFIA

- [1] L. C. Alwan e H. V. Roberts. «Time-Series Modeling for Statistical Process Control». Em: *Journal of Business & Economic Statistics* 6.1 (1988), pp. 87–95. DOI: [10.1080/07350015.1988.10509640](https://doi.org/10.1080/07350015.1988.10509640) (ver p. 59).
- [2] D. W. K. Andrews. «Heteroskedasticity and Autocorrelation Consistent Covariance Matrix Estimation». Em: *Econometrica* 59.3 (1991), pp. 817–858. DOI: [10.2307/2938229](https://doi.org/10.2307/2938229) (ver p. 25).
- [3] *ASHRAE Guideline 14-2014: Measurement of Energy, Demand, and Water Savings*. American Society of Heating, Refrigerating e Air-Conditioning Engineers. Atlanta, GA, 2014 (ver pp. 9, 15).
- [4] Y. Benjamini e Y. Hochberg. «Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing». Em: *Journal of the Royal Statistical Society Series B: Statistical Methodology* 57.1 (1995), pp. 289–300. DOI: [10.1111/j.2517-6161.1995.tb02031.x](https://doi.org/10.1111/j.2517-6161.1995.tb02031.x) (ver p. 25).
- [5] Y. Benjamini e D. Yekutieli. «The control of the false discovery rate in multiple testing under dependency». Em: *The Annals of Statistics* 29.4 (2001), pp. 1165–1188. DOI: [10.1214/aos/1013699998](https://doi.org/10.1214/aos/1013699998) (ver p. 25).
- [6] C. Bergmeir, R. J. Hyndman e B. Koo. «A note on the validity of cross-validation for evaluating autoregressive time series prediction». Em: *Computational Statistics & Data Analysis* 120 (2018), pp. 70–83. DOI: [10.1016/j.csda.2017.11.003](https://doi.org/10.1016/j.csda.2017.11.003) (ver p. 26).
- [7] G. E. P. Box, G. M. Jenkins, G. C. Reinsel e G. M. Ljung. *Time Series Analysis: Forecasting and Control*. 5ª ed. Hoboken, NJ: Wiley, 2015. ISBN: 978-1-118-67502-1 (ver p. 51).
- [8] V. Chernozhukov, I. Fernández-Val e A. Galichon. «Quantile and Probability Curves Without Crossing». Em: *Econometrica* 78.3 (2010), pp. 1093–1125. DOI: [10.3982/ECTA7880](https://doi.org/10.3982/ECTA7880) (ver p. 51).
- [9] G. C. Chow. «Tests of Equality Between Sets of Coefficients in Two Linear Regressions». Em: *Econometrica* 28.3 (1960), pp. 591–605. DOI: [10.2307/1910133](https://doi.org/10.2307/1910133) (ver p. 25).

- [10] C. J. Clopper e E. S. Pearson. «The Use of Confidence or Fiducial Limits Illustrated in the Case of the Binomial». Em: *Biometrika* 26.4 (1934), pp. 404–413. doi: [10.1093/biomet/26.4.404](#) (ver p. 25).
- [11] F. X. Diebold e R. S. Mariano. «Comparing Predictive Accuracy». Em: *Journal of Business & Economic Statistics* 13.3 (1995), pp. 253–263. doi: [10.1080/07350015.1995.10524599](#) (ver p. 25).
- [12] J. Durbin e S. J. Koopman. *Time Series Analysis by State Space Methods*. 2^a ed. Oxford: Oxford University Press, 2012. doi: [10.1093/acprof:oso/9780199641178.001.0001](#) (ver p. 57).
- [13] B. Efron. «Bootstrap Methods: Another Look at the Jackknife». Em: *The Annals of Statistics* 7.1 (1979), pp. 1–26. doi: [10.1214/aos/1176344552](#) (ver p. 25).
- [14] B. Efron e R. J. Tibshirani. *An Introduction to the Bootstrap*. Boca Raton: Chapman & Hall/CRC, 1993. doi: [10.1007/978-1-4899-4541-9](#) (ver p. 25).
- [15] T. Gneiting, F. Balabdaoui e A. E. Raftery. «Probabilistic Forecasts, Calibration and Sharpness». Em: *Journal of the Royal Statistical Society Series B: Statistical Methodology* 69.2 (2007), pp. 243–268. doi: [10.1111/j.1467-9868.2007.00587.x](#) (ver p. 53).
- [16] C. Granger e P. Newbold. «Spurious regressions in econometrics». Em: *Journal of Econometrics* 2.2 (1974), pp. 111–120. doi: [10.1016/0304-4076\(74\)90034-7](#) (ver p. 59).
- [17] P. Hall, J. L. Horowitz e B.-Y. Jing. «On blocking rules for the bootstrap with dependent data». Em: *Biometrika* 82.3 (1995), pp. 561–574. doi: [10.1093/biomet/82.3.561](#) (ver p. 25).
- [18] D. Harvey, S. Leybourne e P. Newbold. «Testing the equality of prediction mean squared errors». Em: *International Journal of Forecasting* 13.2 (1997), pp. 281–291. doi: [10.1016/S0169-2070\(96\)00719-4](#) (ver p. 25).
- [19] T. Hastie e R. Tibshirani. «Generalized Additive Models». Em: *Statistical Science* 1.3 (1986), pp. 297–310. doi: [10.1214/ss/1177013604](#) (ver p. 57).
- [20] J. J. Heckman. «Sample Selection Bias as a Specification Error». Em: *Econometrica* 47.1 (1979), pp. 153–161. doi: [10.2307/1912352](#) (ver p. 50).
- [21] P. W. Holland e R. E. Welsch. «Robust regression using iteratively reweighted least-squares». Em: *Communications in Statistics - Theory and Methods* 6.9 (1977), pp. 813–827. doi: [10.1080/03610927708827533](#) (ver p. 51).
- [22] P. J. Huber. «Robust Estimation of a Location Parameter». Em: *The Annals of Mathematical Statistics* 35.1 (1964), pp. 73–101. doi: [10.1214/aoms/1177703732](#) (ver p. 51).
- [23] P. J. Huber e E. M. Ronchetti. *Robust Statistics*. 2^a ed. Hoboken, NJ: Wiley, 2009. doi: [10.1002/9780470434697](#) (ver p. 51).

- [24] R. J. Hyndman e A. B. Koehler. «Another look at measures of forecast accuracy». Em: *International Journal of Forecasting* 22.4 (2006), pp. 679–688. doi: [10.1016/j.ijforecast.2006.03.001](https://doi.org/10.1016/j.ijforecast.2006.03.001) (ver p. 25).
- [25] *International Performance Measurement and Verification Protocol: Core Concepts (EVO 10000-1:2022)*. Edição a confirmar na versão final. Efficiency Valuation Organization. 2022 (ver pp. 9, 49, 50).
- [26] *ISO 50006:2014 — Energy management systems — Measuring energy performance using energy baselines (EnB) and energy performance indicators (EnPI) — General principles and guidance*. International Organization for Standardization. Geneva, Switzerland, 2014 (ver pp. 1, 2, 8–10, 12, 13, 23, 49, 50).
- [27] *ISO 50006:2023 — Energy management systems — Evaluating energy performance using energy performance indicators and energy baselines*. 2.^a edição; não consultada (ver Secção 7.6). International Organization for Standardization. Geneva, Switzerland, 2023 (ver p. 17).
- [28] *ISO 50015:2014 — Energy management systems — Measurement and verification of energy performance of organizations — General principles and guidance*. International Organization for Standardization. Geneva, Switzerland, 2014 (ver pp. 2, 8, 10, 49).
- [29] R. Kimball e M. Ross. *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. 3.^a ed. Indianapolis, IN: Wiley, 2013. ISBN: 978-1-118-53080-1 (ver p. 21).
- [30] R. Koenker e G. Bassett. «Regression Quantiles». Em: *Econometrica* 46.1 (1978), pp. 33–50. doi: [10.2307/1913643](https://doi.org/10.2307/1913643) (ver p. 51).
- [31] H. R. Künsch. «The Jackknife and the Bootstrap for General Stationary Observations». Em: *The Annals of Statistics* 17.3 (1989), pp. 1217–1241. doi: [10.1214/aos/1176347265](https://doi.org/10.1214/aos/1176347265) (ver p. 25).
- [32] S. N. Lahiri. *Resampling Methods for Dependent Data*. New York: Springer, 2003. doi: [10.1007/978-1-4757-3803-2](https://doi.org/10.1007/978-1-4757-3803-2) (ver p. 25).
- [33] T. L. Lai. «Sequential Changepoint Detection in Quality Control and Dynamical Systems». Em: *Journal of the Royal Statistical Society Series B: Statistical Methodology* 57.4 (1995), pp. 613–644. doi: [10.1111/j.2517-6161.1995.tb02052.x](https://doi.org/10.1111/j.2517-6161.1995.tb02052.x) (ver p. 52).
- [34] D. Lakens. «Equivalence Tests». Em: *Social Psychological and Personality Science* 8.4 (2017), pp. 355–362. doi: [10.1177/1948550617697177](https://doi.org/10.1177/1948550617697177) (ver p. 61).
- [35] J. M. Lourenço. *The aidisclose package: Generative AI disclosure checklist and statements*. Version 1.11.0. 2025. URL: <https://ctan.org/pkg/aidisclose> (ver p. iv).
- [36] *M&V Guidelines: Measurement and Verification for Performance-Based Contracts, Version 4.0*. U.S. Department of Energy, Federal Energy Management Program. 2015 (ver p. 15).

- [37] L. S. Nelson. «The Shewhart Control Chart—Tests for Special Causes». Em: *Journal of Quality Technology* 16.4 (1984), pp. 237–239. doi: [10.1080/00224065.1984.11978921](https://doi.org/10.1080/00224065.1984.11978921) (ver p. 23).
- [38] W. K. Newey e K. D. West. «A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix». Em: *Econometrica* 55.3 (1987), pp. 703–708. doi: [10.2307/1913610](https://doi.org/10.2307/1913610) (ver p. 25).
- [39] B. A. Nosek, C. R. Ebersole, A. C. DeHaven e D. T. Mellor. «The preregistration revolution». Em: *Proceedings of the National Academy of Sciences* 115.11 (2018), pp. 2600–2606. doi: [10.1073/pnas.1708274114](https://doi.org/10.1073/pnas.1708274114) (ver pp. 4, 24).
- [40] NP EN ISO 50001:2019 — *Sistemas de gestão de energia. Requisitos e linhas de orientação para a sua utilização (ISO 50001:2018)*. Instituto Português da Qualidade. Caparica, Portugal, 2019 (ver pp. 1, 8–10, 49).
- [41] E. S. Page. «Continuous Inspection Schemes». Em: *Biometrika* 41.1-2 (1954), pp. 100–115. doi: [10.1093/biomet/41.1-2.100](https://doi.org/10.1093/biomet/41.1-2.100) (ver pp. 23, 52).
- [42] R. D. Peng. «Reproducible Research in Computational Science». Em: *Science* 334.6060 (2011), pp. 1226–1227. doi: [10.1126/science.1213847](https://doi.org/10.1126/science.1213847) (ver p. 26).
- [43] M. H. Pesaran e A. Timmermann. «Selection of estimation window in the presence of breaks». Em: *Journal of Econometrics* 137.1 (2007), pp. 134–161. doi: [10.1016/j.jeconom.2006.03.010](https://doi.org/10.1016/j.jeconom.2006.03.010) (ver p. 57).
- [44] P. J. Rousseeuw e A. M. Leroy. *Robust Regression and Outlier Detection*. New York: Wiley, 1987. doi: [10.1002/0471725382](https://doi.org/10.1002/0471725382) (ver p. 51).
- [45] G. R. Ruiz e C. F. Bandera. «Validation of Calibrated Energy Models: Common Errors». Em: *Energies* 10.10 (2017), p. 1587. doi: [10.3390/en10101587](https://doi.org/10.3390/en10101587) (ver pp. 15, 16).
- [46] G. K. Sandve, A. Nekrutenko, J. Taylor e E. Hovig. «Ten Simple Rules for Reproducible Computational Research». Em: *PLoS Computational Biology* 9.10 (2013), e1003285. doi: [10.1371/journal.pcbi.1003285](https://doi.org/10.1371/journal.pcbi.1003285) (ver p. 26).
- [47] G. Schwarz. «Estimating the Dimension of a Model». Em: *The Annals of Statistics* 6.2 (1978), pp. 461–464. doi: [10.1214/aos/1176344136](https://doi.org/10.1214/aos/1176344136) (ver p. 53).
- [48] P. K. Sen. «Estimates of the Regression Coefficient Based on Kendall’s Tau». Em: *Journal of the American Statistical Association* 63.324 (1968). Estimador proposto originalmente por Theil (1950), *Proc. Kon. Ned. Akad. Wetensch. A* 53, pp. 1379–1389. doi: [10.1080/01621459.1968.10480934](https://doi.org/10.1080/01621459.1968.10480934) (ver p. 51).
- [49] Y. Suchikova, N. Tsybuliak, J. A. T. da Silva e S. Nazarovets. «GAIDeT (Generative AI Delegation Taxonomy): A Taxonomy for Humans to Delegate Tasks to Generative Artificial Intelligence in Scientific Research and Publishing». Em: *Accountability in Research* (2025), pp. 1–27. doi: [10.1080/08989621.2025.2544331](https://doi.org/10.1080/08989621.2025.2544331) (ver p. iv).

-
- [50] L. J. Tashman. «Out-of-sample tests of forecasting accuracy: an analysis and review». Em: *International Journal of Forecasting* 16.4 (2000), pp. 437–450. doi: [10.1016/S0169-2070\(00\)00065-0](https://doi.org/10.1016/S0169-2070(00)00065-0) (ver p. 26).
- [51] The L^AT_EX Project team. *L^AT_EX – A document preparation system*. 1985. URL: <https://www.latex-project.org> (ver p. iv).
- [52] A. C. Tricco, E. Lillie, W. Zarin, K. K. O'Brien, H. Colquhoun, D. Levac, D. Moher, M. D. J. Peters, T. Horsley, L. Weeks, S. Hempel, E. A. Akl, C. Chang, J. McGowan, L. Stewart, L. Hartling, A. Aldcroft, M. G. Wilson, C. Garritty, S. Lewin, C. M. Godfrey, M. T. Macdonald, E. V. Langlois, K. Soares-Weiser, J. Moriarty, T. Clifford, Ö. Tunçalp e S. E. Straus. «PRISMA Extension for Scoping Reviews (PRISMA-ScR): Checklist and Explanation». Em: *Annals of Internal Medicine* 169.7 (2018), pp. 467–473. doi: [10.7326/M18-0850](https://doi.org/10.7326/M18-0850) (ver p. 3).
- [53] D. G. Wardell, H. Moskowitz e R. D. Plante. «Run-Length Distributions of Special-Cause Control Charts for Correlated Processes». Em: *Technometrics* 36.1 (1994), pp. 3–17. doi: [10.1080/00401706.1994.10485393](https://doi.org/10.1080/00401706.1994.10485393) (ver p. 59).
- [54] E. B. Wilson. «Probable Inference, the Law of Succession, and Statistical Inference». Em: *Journal of the American Statistical Association* 22.158 (1927), pp. 209–212. doi: [10.1080/01621459.1927.10502953](https://doi.org/10.1080/01621459.1927.10502953) (ver p. 57).
- [55] S. N. Wood. *Generalized Additive Models: An Introduction with R*. 2^a ed. Boca Raton: Chapman & Hall/CRC, 2017. doi: [10.1201/9781315370279](https://doi.org/10.1201/9781315370279) (ver p. 57).
- [56] G. U. Yule. «Why do we Sometimes get Nonsense-Correlations between Time-Series? A Study in Sampling and the Nature of Time-Series». Em: *Journal of the Royal Statistical Society* 89.1 (1926), pp. 1–63. doi: [10.2307/2341482](https://doi.org/10.2307/2341482) (ver p. 59).

| A

PROTOCOLO DA REVISÃO SISTEMÁTICA E
AMENDMENTS OSF

PROTOCOLO DE VALIDAÇÃO DA EXTRAÇÃO E FLUXO PRISMA

DICIONÁRIO DE DADOS E MAPEAMENTO MESTRE

| D

TABELAS COMPLETAS DO DIAGNÓSTICO

| E

MANUAL DO *DASHBOARD*

REGISTO DA REVISÃO ADVERSARIAL DA METODOLOGIA

DEFINIÇÕES MATEMÁTICAS DOS INSTRUMENTOS DE AVALIAÇÃO

